



POLITECHNIKA POZNAŃSKA

WYDZIAŁ INFORMATYKI I TELEKOMUNIKACJI
Instytut Informatyki

Praca dyplomowa magisterska

ODKRYWANIE ZALEŻNOŚCI MIĘDZY OBIEKTAMI W BAZIE DANYCH

Maria Nowicka, 151851

Promotor
dr hab. inż. Robert Wrembel, prof. PP

POZNAŃ 2026

Streszczenie

Ciągłość grafów pochodzenia danych (*data lineage*) ulega przerwaniu, gdy w potokach przetwarzania pojawiają się obiekty pośrednie: tabele tymczasowe i funkcje definiowane przez użytkownika. Zjawisko to, określane jako *broken lineage*, pozbawia tabele informacji o ich producencie lub konsumencie danych, co utrudnia audyt i kontrolę jakości danych. Dotychczasowe prace modelują ten problem wyłącznie jako predykcję brakujących krawędzi i nie stawiają pytania, które tabele mają zerwane pochodzenie danych. W niniejszej pracy zadanie sformułowano na poziomie węzłów, jako ranking tabel według prawdopodobieństwa zainfekowania zjawiskiem *broken lineage*.

Celem pracy jest zbadanie, w jakim stopniu sama topologia grafu lineage pozwala wskazać takie tabele, bez dostępu do semantyki nazw obiektów i schematów bazy. Zjawisko *broken lineage* symulowano przez kontrolowane usuwanie zadań ze zbioru DLG-DG-23, obejmującego 18 zanonimizowanych, rzeczywistych grafów lineage ze środowiska Huawei Cloud. Porównano trzy klasy metod: heurystyki strukturalne, klasyczne klasyfikatory uczenia maszynowego oparte na cechach pozycji węzła w grafie DAG oraz autorski detektor *LineageDetector*, który łączy cechy topologiczne ze score’em kompletności *peer-consistency* i kalibracją izotoniczną prawdopodobieństw. Ewaluację przeprowadzono w protokole indukcyjnym cross-graph, z kontrolą przecieku wynikającego z trywialnie izolowanych węzłów.

W wariancie uczciwym (z wykluczeniem węzłów izolowanych) *LineageDetector* uzyskał najlepsze wyniki we wszystkich czterech stosowanych miarach jakości. Pole pod krzywą ROC wyniosło 0,771, pole pod krzywą precyzja–czułość 0,435, a precyzja wśród k najwyżej ocenionych tabel 0,443. Błąd Briera, opisujący rzetelność oszacowanych prawdopodobieństw, wyniósł 0,106. Test kolejności par Wilcozona, sparowany po grafach, potwierdził istotność tej przewagi nad heurystykami we wszystkich miarach, a nad metodami boostingowymi w polu pod krzywą precyzja–czułość i błędzie Briera. Różnica wobec Random Forest pozostała natomiast w granicach szumu. Badanie ablacyjne wskazało score kompletności jako składnik odpowiadający za przewagę detektora i ujawniło zarazem, że kalibracja izotoniczna poprawia rzetelność oszacowań prawdopodobieństwa kosztem niewielkiego pogorszenia jakości rankingu.

Skuteczność okazała się stabilna względem odsetka usuwanych zadań i utrzymała się na zewnętrznym grafie DUT, zbudowanym na potrzeby pracy z benchmarku opartego na bazie Northwind i sprowadzonym autorskim adapterem do modelu danych zbioru DLG-DG-23. Ujawniło się natomiast poważne ograniczenie, ponieważ model uczony wyłącznie na grafach małych traci około 0,15 pola pod krzywą ROC przy ocenie grafów o rząd wielkości większych. Wniosek główny jest zatem taki, że sama topologia grafu niesie umiarkowany, lecz użyteczny sygnał o *broken lineage* na poziomie węzłów. Wynik ten wyznacza punkt odniesienia (*topology-only baseline*) dla metod grafowo-semantycznych.

Słowa kluczowe: data lineage, broken lineage, detekcja anomalii w grafach, uczenie indukcyjne, kalibracja prawdopodobieństw.

Abstract

The continuity of data lineage graphs is disrupted whenever processing pipelines rely on intermediate objects such as temporary tables and user-defined functions. This phenomenon, known as *broken lineage*, deprives tables of information about their data producer or consumer and hampers auditing. Existing work models the problem exclusively as missing-edge prediction. This thesis states the task at the node level instead, as a ranking of tables by their probability of being affected by broken lineage.

The goal is to investigate to what extent the topology alone of a lineage graph allows such tables to be identified, without access to object names or database schemas. Broken lineage was simulated by the controlled removal of jobs from the DLG-DG-23 dataset of 18 anonymised, real-world lineage graphs from Huawei Cloud. Three classes of methods were compared: structural heuristics, classical machine-learning classifiers based on DAG-position features, and the proposed *LineageDetector*, which combines topological features with a relational peer-consistency completeness score and isotonic probability calibration. Evaluation followed an inductive cross-graph protocol with control for leakage caused by trivially isolated nodes.

In the fair variant (excluding isolated nodes), *LineageDetector* achieved the best results on all four quality measures used. The area under the ROC curve reached 0.771, the area under the precision–recall curve 0.435, and the precision among the k top-ranked tables 0.443. The Brier score, which reflects the reliability of the estimated probabilities, was 0.106. A Wilcoxon signed-rank test, paired across graphs, confirmed that this advantage is significant over the heuristics on all measures and over the boosting-based classifiers on the area under the precision–recall curve and the Brier score. The difference with respect to Random Forest remained within noise. An ablation study identified the completeness score as the component responsible for the detector’s advantage, while also revealing that isotonic calibration improves the reliability of probability estimates at the cost of a slight loss in ranking quality.

Performance proved stable with respect to the fraction of removed jobs and carried over to the external DUT graph, built for this thesis from a benchmark based on the Northwind database and mapped by a dedicated adapter onto the data model of DLG-DG-23. One substantial limitation was identified: a model trained solely on small graphs loses about 0.15 of the area under the ROC curve when evaluated on graphs an order of magnitude larger. The main conclusion is that graph topology alone carries a moderate yet useful signal about broken lineage at the node level. This result defines a topology-only baseline for graph-semantic methods.

Keywords: data lineage, broken lineage, graph anomaly detection, inductive learning, probability calibration.

Spis treści

Streszczenie	3
Abstract	4
1 Wstęp	10
1.1 Cel i zakres pracy	10
1.2 Pytania badawcze	11
1.3 Wkład własny	12
1.4 Struktura pracy	13
2 Podstawy teoretyczne i przegląd literatury	14
2.1 Data lineage i data provenance	14
2.2 Struktura grafu lineage	15
2.3 Niekompletność grafów lineage	15
2.4 Narzędzia zarządzania lineage w praktyce	16
2.5 Detekcja węzłów o zerwanym lineage	17
2.6 Wykorzystane metody uczenia maszynowego	18
2.6.1 Metody zespołowe	18
2.6.2 Kalibracja prawdopodobieństw	18
2.7 Metryki ewaluacji	19
2.8 Systematyczny przegląd literatury	19
2.8.1 Metodyka przeglądu	20
2.8.2 Prace bazowe – metoda kontrastowa i zbiór danych	21
2.8.3 Metody pokrewne odkrywania zależności lineage	22
2.8.4 Synteza porównawcza	23
2.8.5 Luka badawcza	23
2.8.6 Prace kontekstowe	24
3 Problem i sposób jego rozwiązania	25
3.1 Sformułowanie problemu	25
3.2 Zbiory danych	25
3.2.1 Zbiór DLG-DG-23	26
3.2.2 Zewnętrzny graf DUT	27
3.3 Metodyka symulacji broken lineage przez usuwanie zadań	27
3.3.1 Procedura symulacji i konstrukcja etykiet	27
3.3.2 Kontrola przecieku – wykluczenie węzłów izolowanych	28
3.4 Architektura rozwiązania	28
3.4.1 Moduł wczytywania danych	29

3.4.2	Moduł symulacji usuwania zadań	29
3.4.3	Moduł ewaluacji i metryki rankingowe	29
3.5	Zaimplementowane metody detekcji	30
3.5.1	Heurystyki strukturalne	30
3.5.2	Klasyczne metody uczenia maszynowego	31
3.5.3	Autorski detektor LineageDetector	32
3.6	Implementacja	33
3.6.1	Stos technologiczny	33
3.6.2	Organizacja repozytorium	33
3.6.3	Format danych i wczytywanie	33
3.6.4	Wyznaczanie score'u peer-consistency	34
3.6.5	Protokół indukcyjny w kodzie	35
3.6.6	Złożoność obliczeniowa	35
3.7	Testy jednostkowe i odtwarzalność	36
3.7.1	Zakres testów	36
3.7.2	Odtwarzalność wyników	36
3.8	Dostępność implementacji i pochodzenie algorytmów	37
4	Ocena rozwiązań	38
4.1	Badanie wstępne – predykcja krawędzi	38
4.2	Wyniki detekcji węzłów o zerwanym lineage	39
4.3	Wyniki w rozbiciu na poszczególne grafy	40
4.4	Istotność statystyczna różnic	41
4.5	Badanie ablacyjne detektora	42
4.6	Kontrola przecieku i analiza wrażliwości	43
4.6.1	Przeciek izolacji	43
4.6.2	Wrażliwość na odsetek usuwanych zadań	44
4.7	Ważność cech	44
4.8	Warianty protokołu ewaluacji	46
4.8.1	Protokół transduktywny	46
4.8.2	Generalizacja na większą skalę	46
4.8.3	Pojedyncze zdarzenie broken lineage	47
4.9	Test na grafie spoza zbioru DLG-DG-23	47
4.10	Analiza wyników	49
4.11	Zagrożenia trafności	49
4.11.1	Trafność konstrukcji	50
4.11.2	Trafność wewnętrzna	50
4.11.3	Trafność zewnętrzna	50
4.11.4	Trafność wnioskowania statystycznego	51
5	Uwagi końcowe	52
5.1	Podsumowanie	52
5.2	Kierunki dalszych badań	53
	Literatura	55
A	Instrukcja uruchomienia i zawartość repozytorium	59
A.1	Wymagania i instalacja	59

A.2	Odtworzenie wyników rozdziału 4	59
A.3	Zawartość repozytorium	60
B	Pełne wyniki eksperymentów	61
C	Przegląd konfiguracji testu cross-dataset	65

Wykaz skrótów i oznaczeń

Skróty

AUC-PR	pole pod krzywą precyzja–czułość (<i>Area Under the Precision–Recall Curve</i>)
AUC-ROC	pole pod krzywą ROC (<i>Area Under the Receiver Operating Characteristic Curve</i>)
CSV	format danych rozdzielanych przecinkami (<i>Comma-Separated Values</i>)
CTE	wspólne wyrażenie tablicowe (<i>Common Table Expression</i>)
DAG	skierowany graf acykliczny (<i>Directed Acyclic Graph</i>)
DBLP	bibliograficzna baza publikacji informatycznych (<i>Digital Bibliography & Library Project</i>)
DLG-DG-23	zbiór danych grafów lineage opublikowany przez Chen et al. [11]
DUT	zewnętrzny graf testowy zbudowany z benchmarku Dutkiewicza et al. [18]
ETL	proces ekstrakcji, transformacji i ładowania danych (<i>Extract, Transform, Load</i>)
GNN	grafowa sieć neuronowa (<i>Graph Neural Network</i>)
HGNN	heterogeniczna grafowa sieć neuronowa (<i>Heterogeneous Graph Neural Network</i>)
HGT	heterogeniczny transformer grafowy (<i>Heterogeneous Graph Transformer</i>)
LLM	duży model językowy (<i>Large Language Model</i>)
MLP	perceptron wielowarstwowy (<i>Multilayer Perceptron</i>)
P@k	precyzja na k czołowych pozycjach rankingu (<i>Precision@k</i>)
PGK	jądro grafów proveniencji (<i>Provenance Graph Kernel</i>)
PROV-O	ontologia proveniencji W3C (<i>W3C Provenance Ontology</i>)
RDF	model opisu zasobów (<i>Resource Description Framework</i>)
R-GCN	relacyjna grafowa sieć konwolucyjna (<i>Relational Graph Convolutional Network</i>)
RODO	ogólne rozporządzenie o ochronie danych
RUSBoost	boosting z losowym podpróbkowaniem (<i>Random Under-Sampling Boosting</i>)
SLR	systematyczny przegląd literatury (<i>Systematic Literature Review</i>)
SQL	strukturalny język zapytań (<i>Structured Query Language</i>)
UDF	funkcja definiowana przez użytkownika (<i>User-Defined Function</i>)
UUID	uniwersalny unikatowy identyfikator (<i>Universally Unique Identifier</i>)
W3C	konsorcjum standardów sieciowych (<i>World Wide Web Consortium</i>)

Oznaczenia

$G = (V, E)$	graf lineage: zbiór węzłów V i krawędzi E
V_T, V_J, V_F	zbiory węzłów typu tabela, zadanie i pole
G_{obs}	graf obserwowany, powstały przez usunięcie zadań z G
$s(t)$	wynik detekcji przypisany tabeli t , interpretowany jako $p(t \text{ zainfekowana})$
$P(t), C(t)$	zbiory peerów tabeli t po stronie producenta i konsumenta
in_df, out_df	liczba wejściowych i wyjściowych krawędzi <i>DATA_FLOW</i> węzła
k	liczba czołowych pozycji rankingu branych pod uwagę, w pracy równa liczbie tabel zainfekowanych
m	liczba usuniętych zadań
α	poziom istotności statystycznej
Δ	mediana różnicy między porównywanymi metodami

Rozdział 1

Wstęp

Współczesne systemy bazodanowe przetwarzają dane w złożonych potokach transformacji. W środowiskach korporacyjnych dane są wielokrotnie agregowane i przekształcane przez sekwencje zapytań, a wyniki pośrednie przechowywane w tabelach tymczasowych. Obiekty te znikają po zakończeniu przetwarzania, a wraz z nimi ślad po wykonanych transformacjach. Ustalenie, skąd pochodzi dana wartość w tabeli wynikowej i jakie operacje ją wytworzyły, przestaje wówczas być możliwe. Śledzeniem takich zależności zajmuje się dziedzina określana w literaturze jako *data lineage* lub *data provenance* [50, 60]. Brak pełnej informacji o przepływie danych utrudnia audyt i kontrolę jakości danych.

Formalnie problem ten można wyrazić w kategoriach teorii grafów. Graf zależności (ang. *lineage graph*) reprezentuje przepływ danych między obiektami bazy takimi jak tabele, widoki, zapytania oraz ich atrybutami. Gdy pewne węzły lub krawędzie zostaną utracone (np. z powodu usunięcia tabeli tymczasowej lub zastosowania funkcji definiowanej przez użytkownika), mówi się o zjawisku *broken lineage* [6].

Celem niniejszej pracy jest *detekcja obiektów bazodanowych o zerwanym lineage*, czyli tabel, które w wyniku *broken lineage* utraciły producenta lub konsumenta danych. W odróżnieniu od dotychczasowych prac, które modelują *broken lineage* jako predykcję konkretnych brakujących krawędzi, w pracy sformułowano zadanie na poziomie węzłów, czyli jako uszeregowanie tabel według prawdopodobieństwa, że ich lineage jest niekompletny. Podejście to jest komplementarne wobec predykcji krawędzi i może ją poprzedzać, ponieważ najpierw wskazuje się podejrzane tabele, a dopiero potem można próbować odtwarzać ich zależności.

W sektorze finansowym banki są zobowiązane do wykazania, które transakcje źródłowe złożyły się na poszczególne pozycje raportów kwartalnych. Przerwanie grafu zależności w warstwie ETL (*Extract, Transform, Load*) uniemożliwia przeprowadzenie takiego audytu [6]. Podobne konsekwencje niesie Ogólne rozporządzenie o ochronie danych (RODO) [47], gdyż brak pełnego grafu lineage sprawia, że dotarcie do wszystkich kopii danych konkretnej osoby jest czasochłonne lub niemożliwe, co może skutkować nałożeniem kar finansowych [6].

1.1 Cel i zakres pracy

Celem pracy jest zbadanie, w jakim stopniu sama topologia grafu lineage pozwala wskazać tabele o zerwanej ciągłości pochodzenia danych, bez dostępu do semantyki nazw obiektów, schematów bazy czy ontologii. Zadanie sformułowano jako ranking węzłów typu *Data Table* według

prawdopodobieństwa, że tabela została dotknięta zjawiskiem broken lineage. Tabele takie nazywane są dalej *zainfekowanymi* (ang. *infected*). Zakres obejmuje:

- metodykę symulacji broken lineage przez usuwanie zadań i wyznaczanie zbioru tabel zainfekowanych jako etykiet referencyjnych,
- porównanie trzech klas metod detekcji: heurystyk strukturalnych, klasycznych klasyfikatorów uczenia maszynowego opartych na cechach pozycji węzła w grafie DAG oraz autorskiego detektora *LineageDetector*,
- ewaluację w protokole indukcyjnym cross-graph (trenowanie na części grafów, testowanie na grafach niewidzianych),
- analizę wrażliwości wyniku na odsetek usuwanych zadań oraz kontrolę przecieku wynikającego z trywialnie izolowanych węzłów,
- test przenośności metody na zewnętrznym grafie DUT wraz z opracowaniem adaptera, który sprowadza ten graf do modelu danych zbioru DLG-DG-23.

Eksperymenty główne przeprowadzono na zbiorze danych DLG-DG-23, obejmującym 18 zanonimizowanych grafów lineage ze środowiska Huawei Cloud [11]. Przenośność metody sprawdzono dodatkowo na grafie spoza tego zbioru, zbudowanym na podstawie benchmarku opracowanego przez Dutkiewicza et al. [18]. Benchmark ten opisuje syntetyczne scenariusze SQL wykonywane na bazie *Northwind*, a lineage zapisuje na poziomie pojedynczych wierszy w postaci RDF i CSV. Ponieważ reprezentacja ta jest niezgodna z modelem tabela–zadanie stosowanym w DLG-DG-23, w ramach pracy opracowano adapter agregujący zależności wierszowe do poziomu tabel. Powstały w ten sposób graf, oznaczany dalej jako graf DUT, opisano w sekcji 3.2.2, a wyniki testu w sekcji 4.9.

Zakres pracy nie obejmuje odtworzenia rzeczywistego schematu bazy danych, analizy treści zanonimizowanych danych ani odtwarzania konkretnych brakujących krawędzi. Predykcja krawędzi została zachowana jako *badanie wstępne*, którego wyniki motywują zmianę ujęcia problemu na poziom węzłów (sekcja 4.1).

Temat pracy formułuje zadanie jako odkrywanie brakujących krawędzi w grafie zależności. Ujęcie węzłowe przyjęto w toku prac, w porozumieniu z promotorem, na podstawie wyników badania wstępnego. Skuteczność predykcji pojedynczych krawędzi na zbiorze DLG-DG-23 utrzymywała się w pobliżu poziomu losowego przy wysokiej wariancji między grafami, co czyniło zadanie w tej postaci nierozstrzygalnym przy sygnale czysto topologicznym. Cel praktyczny pozostaje ten sam, to znaczy wskazanie obiektów o niekompletnym pochodzeniu danych. Zmienia się natomiast poziom, na którym zadanie postawiono, a predykcja krawędzi pozostaje naturalnym krokiem następnym wobec wskazanych tabel.

1.2 Pytania badawcze

Na podstawie systematycznego przeglądu literatury (sekcja 2.8) sformułowano cztery pytania badawcze, na które praca odpowiada w sekcji 5.1:

- PB1** Jakie techniki algorytmiczne są wykorzystywane do ekstrakcji i rekonstrukcji grafów pochodzenia danych ze źródeł nieustrukturyzowanych, takich jak logi zapytań lub częściowe metadane systemowe?
- PB2** W jaki sposób metody uczenia maszynowego mogą zostać zaadaptowane do wykrywania niekompletności grafu zależności bazodanowych?

PB3 Jakie są ograniczenia obecnych metod w obsłudze struktur niestandardowych, czyli zapytań rekurencyjnych (CTE) oraz funkcji definiowanych przez użytkownika (UDF), stanowiących „czarne skrzynki” przetwarzania?

PB4 Jakie metryki jakości oraz zbiory danych referencyjnych są właściwe do obiektywnej ewaluacji algorytmów odkrywania lineage?

Pytanie PB2 zostało w toku prac przeformułowane. W przeglądzie literatury postawiono je w postaci węższej, jako pytanie o adaptację metod uczenia maszynowego do predykcji brakujących krawędzi, zgodnie z dominującym w literaturze ujęciem problemu. Badanie wstępne (sekcja 4.1) wykazało jednak, że przy rzadkości grafów zbioru DLG-DG-23 predykcja krawędzi nie daje wyników odbiegających od poziomu losowego. Pytanie rozszerzono zatem do ogólniejszej postaci przytoczonej wyżej, obejmującej również ujęcie węzłowe. Na tym przeformułowaniu opiera się dalsza część pracy.

1.3 Wkład własny

Podstawowym wkładem pracy jest sformułowanie problemu broken lineage na poziomie węzłów. Zamiast pytać, która krawędź została utracona, praca pyta, które tabele są dotknięte brakiem, i formalizuje to zadanie jako ranking tabel według prawdopodobieństwa zainfekowania (sekcja 3.1). Ujęcie to nie występuje w dotychczasowej literaturze o lineage bazodanowym (sekcja 2.8.4).

Z tak postawionym zadaniem wiąże się opracowana metodyka symulacji broken lineage przez usuwanie zadań. Usunięcie całego węzła-zadania odwzorowuje mechanizm zjawiska i pozwala automatycznie wyznaczyć etykiety referencyjne, bez ręcznego znakowania danych (sekcja 3.3). Częścią protokołu ewaluacji uczyniono ponadto kontrolę przecieku izolacji. Zidentyfikowano i zmierzono trywialny przeciek „tabela izolowana $\Rightarrow$ zainfekowana”, obejmujący 19–35% pozytywów, oraz wprowadzono wariant ewaluacji, który go usuwa (sekcja 3.3.2). Kontrola taka nie była stosowana w dotychczasowych pracach o broken lineage.

Centralnym elementem pracy jest autorski detektor LineageDetector, który łączy cechy pozycji węzła w grafie DAG z relacyjnym score’em kompletności *peer-consistency* i kalibracją prawdopodobieństw (sekcja 3.5.3). Badanie ablacyjne wykazało, że przewagę detektora nad klasyfikatorem bazowym zapewnia właśnie sygnał relacyjny (sekcja 4.5).

Wyniki poddano ewaluacji z kontrolą rzetelności. Zastosowano protokół indukcyjny cross-graph, testy istotności statystycznej sparowane po grafach, analizę wrażliwości oraz badanie ablacyjne. Przenośność metody sprawdzono na zewnętrznym grafie DUT, dla którego opracowano adapter przekształcający lineage zapisany na poziomie wierszy do modelu tabela–zadanie zbioru DLG-DG-23 (sekcje 3.2.2 i 4.9). Wyniki raportowane są wraz z przypadkami, w których przewagi wykazać się nie udało (sekcja 4.4). Całość uzupełnia odtwarzalna implementacja. Kod, testy jednostkowe i skrypty odtwarzające każdy eksperyment udostępniono w publicznym repozytorium (sekcja 3.8, dodatek A).

Do wkładu pracy zaliczyć należy również wynik negatywny, czyli wykazanie, że na rzeczywistych, rzadkich grafach lineage pozbawionych semantyki nazw predykcja brakujących krawędzi nie przewyższa poziomu losowego (sekcja 4.1). Obserwacja ta jest zbieżna z wynikami uzyskanymi niezależnie metodami grafowo-semantycznymi [18] i stanowi bezpośrednie uzasadnienie zmiany ujęcia problemu.

1.4 Struktura pracy

Celem pracy jest opracowanie i eksperymentalna ocena metody wskazywania tabel o zerwanym lineage wyłącznie na podstawie topologii grafu pochodzenia danych.

Struktura pracy jest następująca. W rozdziale 2 przedstawiono pojęcia podstawowe (data lineage, data provenance, broken lineage oraz detekcja anomalii w grafach), wykorzystane metody uczenia maszynowego, stosowane metryki ewaluacji oraz systematyczny przegląd literatury. Rozdział 3 jest poświęcony sformułowaniu problemu, wykorzystanym danym (zbiorowi DLG-DG-23 i zewnętrznemu grafowi DUT), metodyce symulacji broken lineage przez usuwanie zadań, architekturze i implementacji rozwiązania oraz zaimplementowanym metodom detekcji. Rozdział 4 zawiera wyniki eksperymentów przeprowadzonych na zbiorze DLG-DG-23 i na grafie DUT wraz z ich analizą statystyczną i omówieniem zagrożeń trafności. Rozdział 5 stanowi podsumowanie pracy i wskazuje kierunki dalszych badań. Dodatek A zawiera instrukcję uruchomienia implementacji, dodatek B pełne wyniki eksperymentów dla wszystkich grafów, a dodatek C przegląd konfiguracji testu na grafie zewnętrznym.

Rozdział 2

Podstawy teoretyczne i przegląd literatury

Rozdział wprowadza pojęcia potrzebne w dalszych częściach pracy. W sekcji 2.1 zdefiniowano *data lineage* i *data provenance*, a w sekcji 2.2 opisano strukturę grafów lineage. Sekcja 2.3 omawia przyczyny niekompletności grafów, sekcja 2.4 przemysłowe narzędzia zarządzania lineage, a sekcja 2.5 zadanie detekcji węzłów o zerwanym lineage. Sekcja 2.6 przedstawia wykorzystane metody uczenia maszynowego, sekcja 2.7 stosowane metryki ewaluacji, a sekcja 2.8 systematyczny przegląd literatury.

2.1 Data lineage i data provenance

Pojęcia *data lineage* i *data provenance* są w literaturze stosowane zarówno zamiennie, jak i z różnieniem semantycznym [50]. W węższym ujęciu *data lineage* odnosi się do śledzenia przepływu informacji przez kolejne etapy przetwarzania, opisuje, przez jakie transformacje przeszły dane i jak zmieniała się ich postać. Z kolei *data provenance* kładzie nacisk na pochodzenie i autentyczność danych, rejestruje, skąd dane zostały pobrane i kto je wytworzył. W praktyce granica między tymi pojęciami jest płynna i większość opracowań traktuje je jako synonimy. Takie podejście przyjęto również w niniejszej pracy.

Znajomość historii danych ma wymierne znaczenie praktyczne. W systemach raportowych możliwość odtworzenia ścieżki transformacji pozwala zlokalizować źródło błędnych wartości. Bez tej informacji ręczna weryfikacja wielkich zbiorów danych staje się nieefektywna. Innym przykładem jest bezpieczne usuwanie obiektów bazy. Tabela pozornie niepowiązana z żadnym procesem może w rzeczywistości dostarczać danych do raportów końcowych, a jej usunięcie spowoduje utratę danych bez widocznego komunikatu błędu [6].

W literaturze wyróżnia się trzy klasyczne rodzaje proveniencji, wprowadzone przez Bunemana et al. [10] i rozwinięte w kolejnych pracach [21, 26]. Proveniencja typu *why* odpowiada na pytanie, które krotki danych źródłowych przyczyniły się do powstania danej krotki wynikowej. Proveniencja *where* wskazuje, z których konkretnie komórek pochodzi wartość. Proveniencja *how* opisuje natomiast sposób, w jaki wynik powstał, czyli kombinację operacji, którym poddano dane źródłowe. Jej formalizacją są półpierścienie proveniencji [21].


Podział ten odnosi się do poziomu pojedynczych wartości i krotek, określanego jako proveniencja *drobnoziarnista* (ang. *fine-grained*). W praktyce systemów zarządzania danymi stosuje się częściej ujęcie *gruboziarniste* (ang. *coarse-grained*), operujące na poziomie całych obiektów: tabel, widoków i zadań przetwarzania [50]. Powodem jest koszt, ponieważ śledzenie pochodzenia każdej wartości wymaga instrumentacji systemu zarządzania bazą danych i generuje wolumen metadanych porównywalny z samymi danymi [13]. Niniejsza praca operuje na poziomie gruboziarnistym. Przedmiotem analizy są zależności między tabelami a zadaniami, a nie pochodzenie poszczególnych wartości.

Standaryzację zapisu proveniencji wprowadza ontologia *PROV-O* [36], rekomendacja W3C definiująca trzy podstawowe klasy (*Entity* jako daną, *Activity* jako proces i *Agent* jako podmiot odpowiedzialny) oraz relacje między nimi. Model tabela–zadanie stosowany w niniejszej pracy odpowiada podzbiorowi tej ontologii, w którym tabele pełnią rolę encji, zadania rolę aktywności, a krawędzie *DATA_FLOW* odpowiadają relacjom *used* i *wasGeneratedBy*.

2.2 Struktura grafu lineage

Graf lineage reprezentuje przepływ danych między obiektami bazy danych. Węzłami są obiekty przetwarzania: tabele i widoki przechowujące dane, zadania (zapytania SQL, procesy ETL) je przekształcające, oraz atrybuty (pola) tabel. Krawędzie skierowane wyrażają przepływ danych, z tabeli do zadania, które ją czyta, oraz z zadania do tabeli, którą zapisuje, a także relację przynależności pola do tabeli. Podgraf przepływu danych między tabelami a zadaniami jest *dwudzielny* i skierowany, co pozwala interpretować go jako graf skierowany acykliczny (DAG). W niniejszej pracy przedmiotem detekcji są wyłącznie węzły reprezentujące tabele.

Rysunek 2.1 przedstawia poglądowy fragment grafu przepływu danych przed usunięciem zadania i po jego usunięciu. Usunięcie zadania J1 pozbawia tabele T1 i T2 konsumenta, a tabelę T3 producenta. Wszystkie trzy stają się zainfekowane, choć pozostają w grafie (T3 zachowuje połączenie z zadaniem J2).



RYСУNEK 2.1: Fragment grafu przepływu danych: (a) graf oryginalny, (b) graf po usunięciu zadania J1. Tabele zainfekowane oznaczono kolorem czerwonym, krawędzie utracone – linią przerywaną.

Wszystkie eksperymenty oparto na zbiorze danych DLG-DG-23. Jego pełną charakterystykę, obejmującą reprezentację typów węzłów i krawędzi, anonimizację oraz statystyki 18 grafów, zebrano w sekcji 3.2.

2.3 Niekompletność grafów lineage

Graf lineage bywa niekompletny z kilku powodów. Tabele tymczasowe, tworzone na potrzeby pojedynczej sesji lub procesu ETL, znikają po jego zakończeniu. Jeśli pośredniczyły w przepływie danych między dwoma trwałymi tabelami, znika wraz z nimi odpowiedni fragment grafu. Analogiczny skutek mają widoki zmaterializowane tworzone tymczasowo oraz funkcje definiowane przez użytkownika (ang. *User-Defined Function*, UDF), które opakowują logikę transformacji bez jawnego zapisu przepływu danych [60].

Zjawisko to, określane jako *broken lineage*, sprawia, że tabela traci część lub całość informacji o swoim pochodzeniu i przestaje mieć widocznego producenta danych (zadanie zapisujące) lub ich konsumenta (zadanie czytające), mimo że rzeczywista zależność istnieje. W niniejszej pracy problem *broken lineage* jest modelowany jako zadanie *detekcji zainfekowanych węzłów*, w którym dla każdej tabeli algorytm ocenia prawdopodobieństwo, że jej lineage został zerwany. Formalne ujęcie problemu przedstawiono w rozdziale 3.

Tabela 2.1 systematyzuje mechanizmy prowadzące do niekompletności grafu lineage. Wspólny im jest schemat, w którym transformacja zachodzi, lecz pozostaje niewidoczna dla narzędzi zbierających metadane, przez co w grafie brakuje węzła pośredniczącego albo krawędzi.

TABELA 2.1: Przyczyny *broken lineage* i ich konsekwencje dla grafu zależności.

Przyczyna	Mechanizm	Skutek w grafie
Tabela tymczasowa	Obiekt pośredniczący usuwany po zakończeniu sesji lub procesu ETL [6, 18]	Znika węzeł pośredni, a tabela źródłowa i docelowa stają się rozłączne
Funkcja definiowana przez użytkownika (UDF)	Logika transformacji ukryta w kodzie proceduralnym, nieanalizowanym przez parser SQL [60]	Krawędź istnieje w rzeczywistości, lecz nie jest rejestrowana
Zapytanie rekurencyjne (CTE)	Wielokrotne odwołanie do tej samej relacji utrudnia jednoznaczne przypisanie pochodzenia [17]	Zależność zostaje zapisana niepełnie lub pominięta
Widok zmaterializowany	Widok tworzony tymczasowo na potrzeby jednego procesu [18]	Skutek taki jak przy tabeli tymczasowej
Przetwarzanie zewnętrzne	Transformacja wykonana poza systemem zarządzania bazą danych (skrypt, zadanie Spark)	Brak jakiegokolwiek śladu w metadanych bazy
Partycjonowanie i kopiowanie	Dane rozdzielane lub replikowane bez jawnego zapisu relacji [18]	Pojedyncza zależność rozpada się na wiele nieudokumentowanych

W niniejszej pracy wszystkie te mechanizmy modelowane są jednolicie, jako usunięcie węzła-zadania wraz z jego krawędziami (sekcja 3.3). Uproszczenie to jest celowe. Detekcja opiera się na skutku zerwania widocznym w topologii, a nie na jego przyczynie, dzięki czemu metoda nie wymaga osobnej obsługi każdego mechanizmu.

2.4 Narzędzia zarządzania lineage w praktyce

Zagadnienie omawiane w pracy ma bezpośrednie odzwierciedlenie w narzędziach przemysłowych klasy *data governance*. Tabela 2.2 zestawia najczęściej stosowane rozwiązania wraz ze sposobem pozyskiwania przez nie informacji o pochodzeniu danych.

Rozwiązania te dzielą jedno ograniczenie, ważne dla uzasadnienia niniejszej pracy. Wszystkie zbierają lineage *prospektywnie*, czyli w chwili wykonania zadania i tylko dla zadań objętych instrumentacją. Żadne z nich nie oferuje mechanizmu *retrospektywnego* wskazania miejsc, w których zebrany graf jest niekompletny. Dotyczy to systemów zastanych, przetwarzania poza systemem bazy danych oraz audytu *post hoc*, czyli prowadzonego po zakończeniu przetwarzania, gdy metadanych nie można już zebrać w chwili wykonania zadań [9]. W takich sytuacjach narzędzie nie sygnalizuje braku, a jedynie pokazuje graf uboższy od rzeczywistego. Tę właśnie lukę adresuje detekcja tabel o zerwanym lineage, będąca przedmiotem niniejszej pracy.

TABELA 2.2: Wybrane narzędzia zarządzania lineage i stosowane przez nie metody akwizycji metadanych.

Narzędzie	Metoda akwizycji	Podatność na broken lineage
Apache Atlas [4]	Wtyczki (<i>hooks</i>) do systemów Hive, Spark, Kafka	Brak śladu przy przetwarzaniu poza zintegrowanymi systemami
OpenLineage / Marquez [45]	Otwarty standard zdarzeń emitowanych przez zadania	Konieczność instrumentacji każdego zadania, zadania nieobsługiwane pozostają niewidoczne
Spline [1]	Przechwytywanie planów wykonania Apache Spark	Ograniczenie do jednej platformy przetwarzania
DataHub [14], Collibra [12]	Parsowanie SQL oraz import metadanych z katalogów	Parser nie sięga do wnętrza UDF ani kodu proceduralnego

2.5 Detekcja węzłów o zerwanym lineage

Detekcja anomalii na poziomie węzłów grafu polega na przypisaniu każdemu węzłowi wyniku (score) wyrażającego stopień, w jakim odbiega on od wzorca uznawanego za poprawny, a następnie na uszeregowaniu węzłów według tego wyniku. W kontekście grafów lineage węzłem podejrzanym jest tabela, której sąsiedztwo w grafie DAG sugeruje niekompletność pochodzenia danych.

Dziedzina detekcji anomalii w grafach dysponuje ustaloną taksonomią metod [2, 39]. Metody *oparte na cechach* opisują węzeł wektorem statystyk strukturalnych (stopień, współczynnik growowania, miary centralności), a następnie stosują klasyfikator lub detektor wartości odstających. Metody *spektralne* i oparte na faktoryzacji wykrywają węzły odbiegające od struktury niskiego rzędu przybliżającej graf. Metody *oparte na głębokim uczeniu*, przede wszystkim grafowe sieci neuronowe, uczą reprezentacji węzła z propagacją komunikatów między sąsiadami. Niniejsza praca sytuuje się w pierwszej z tych rodzin. Węzeł opisywany jest wektorem cech pozycji w grafie DAG, uzupełnionym o sygnał relacyjny, a decyzję podejmuje klasyfikator uczony indukcyjnie. Zdecydował o tym rozmiar zbioru, bo 18 grafów to zbyt mało, by trenować model głęboki bez ryzyka przeuczenia, a także sam cel pracy, którym jest wyznaczenie punktu odniesienia dla metod bogatszych, a nie maksymalizacja skuteczności.

Zasadnicza różnica względem klasycznej detekcji anomalii polega tu na tym, że anomalia nie jest własnością wewnętrzną węzła, lecz skutkiem usunięcia innego węzła. Tabela zainfekowana sama w sobie nie wygląda podejrzanie, lecz przypomina poprawną tabelę innego rodzaju, źródłową lub końcową. Odróżnienie jej wymaga zatem porównania z kontekstem, a nie wykrycia wartości odstających.

W przeciwieństwie do predykcji krawędzi, zadanie nie polega na wskazaniu, której krawędzi brakuje, lecz które tabele są dotknięte brakiem. Jest to zadanie rankingowe, oceniane metrykami czułymi na uszeregowanie (sekcja 2.7), a nie zadanie klasyfikacji przy ustalonym progu. Motywacja dla tego ujęcia wynika z ograniczeń danych DLG-DG-23. Rzadkość grafów sprawia, że sygnał o konkretnej brakującej parze obiektów jest zbyt słaby (sekcja 4.1), natomiast wskazanie podejrzanych tabel pozostaje wykonalne.

W pracy zastosowano trzy klasy metod detekcji. Pierwszą stanowią heurystyki strukturalne, czyli reguły oparte wyłącznie na pozycji węzła w grafie (stopień, rola korzenia lub liścia), do których zaliczono również autorski score kompletności *peer-consistency* użyty samodzielnie. Metody te nie wymagają uczenia. Drugą klasę tworzą klasyczne metody uczenia maszynowego, czyli Random Forest, RUSBoost i LightGBM, które klasyfikują węzeł na podstawie wektora cech opisujących jego pozycję w grafie DAG. Ze względu na anonimizację identyfikatorów (UUID) nie można w nich

wykorzystać metryk podobieństwa nazw, takich jak miara Jaro–Winklera stosowana przez Boińskiego et al. [6]. Trzecią klasę stanowi autorski detektor LineageDetector, który łączy cechy pozycji w DAG, relacyjny score kompletności oraz kalibrację izotoniczną, a jego wynikiem jest oszacowanie $p(\text{zainfekowana})$ dla każdej tabeli. Implementację wszystkich trzech klas opisano w sekcji 3.5.

2.6 Wykorzystane metody uczenia maszynowego

Sekcja przedstawia podstawy teoretyczne metod zastosowanych w rozdziale 3. Omówiono dwie grupy technik, odpowiadające dwu różnym wymaganiom stawianym detektorowi. Pierwszą stanowią metody zespołowe, łączące predykcje wielu słabych klasyfikatorów w jedną decyzję. Wybrano je ze względu na zdolność do pracy przy silnie nie zrównoważonym rozkładzie klas, charakterystycznym dla zadania detekcji, w którym tabele zainfekowane stanowią kilkanaście procent kandydatów.

Drugą grupą jest kalibracja prawdopodobieństw, czyli przekształcenie surowych wyników klasyfikatora w wartości dające się interpretować jako prawdopodobieństwa. Rozróżnienie to ma znaczenie praktyczne, ponieważ uszeregowanie tabel do ręcznej inspekcji wymaga jedynie poprawnej kolejności, natomiast progowanie ryzyka lub szacowanie kosztu przeglądu wymaga już rzetelnych oszacowań prawdopodobieństwa. Obie własności oceniono osobno w rozdziale 4.

2.6.1 Metody zespołowe

Random Forest [7] buduje zespół drzew decyzyjnych, z których każde uczy się na losowej podpróbie obserwacji (*bagging*) i rozważa w każdym podziale losowy podzbiór cech. Uśrednienie predykcji redukuje wariancję pojedynczego drzewa, zachowując jego zdolność do modelowania nieliniowych interakcji między cechami. Niezrównoważenie klas kompensuje się wagami odwrotnie proporcjonalnymi do ich liczności.

Boosting gradientowy [20] buduje drzewa sekwencyjnie, przy czym każde kolejne minimalizuje błąd reszkowy poprzedników. *LightGBM* [31] wprowadza dwa usprawnienia obniżające koszt obliczeniowy: próbkowanie obserwacji o dużym gradiencie oraz łączenie cech wzajemnie wykluczających się. Drzewo rozrasta się przy tym liściami zamiast poziomami, co przy tej samej liczbie węzłów daje mniejszy błąd.

RUSBoost [54] łączy boosting typu AdaBoost z losowym podpróbkowaniem klasy większościowej przed każdą iteracją. Metoda powstała specjalnie dla danych nie zrównoważonych i jest tańsza obliczeniowo od podejść opartych na generowaniu obserwacji syntetycznych. W niniejszej pracy zastosowano ją przede wszystkim dla bezpośredniej porównywalności z wynikami Boińskiego et al. [6], u których osiągnęła najlepszy rezultat.

2.6.2 Kalibracja prawdopodobieństw

Klasyfikator zwracający poprawny ranking nie musi zwracać poprawnych prawdopodobieństw. Metody zespołowe oparte na drzewach są pod tym względem systematycznie obciążone, ponieważ przesuwały oszacowania ku środkowi przedziału, rzadko wskazując wartości bliskie 0 lub 1 [44]. Ponieważ zadanie postawione w niniejszej pracy wymaga oszacowania $p(\text{tabela zainfekowana})$, a nie tylko uszeregowania, zastosowano kalibrację.

Regresja izotoniczna [61] dopasowuje niemalejącą funkcję schodkową przekształcającą surowy wynik klasyfikatora w prawdopodobieństwo, minimalizując błąd kwadratowy na zbiorze kalibracyjnym. W odróżnieniu od kalibracji Platt’a [49] nie zakłada określonej postaci funkcyjnej, jest jednak bardziej podatna na przeuczenie przy małej liczbie obserwacji [44]. Ma przy tym własność istotną

dla wyników rozdziału 4. Jako funkcja schodkowa przypisuje obserwacjom o zbliżonych wynikach identyczne prawdopodobieństwo i wprowadza do rankingu remis nieobecne w wyniku surowym.

2.7 Metryki ewaluacji

Zadanie detekcji ma charakter rankingowy, dlatego stosuje się metryki oceniające jakość uszeregowania węzłów, a nie pojedynczej decyzji przy progu:

- **AUC-ROC** [19]: pole pod krzywą ROC, mierzące zdolność modelu do postawienia zainfekowanej tabeli wyżej w rankingu niż czystej,
- **AUC-PR** [15]: pole pod krzywą precyzja–czułość, szczególnie istotne przy nie zrównoważonych klasach, gdy liczba tabel czystych wielokrotnie przewyższa liczbę zainfekowanych,
- **Precision@k** [40]: frakcja tabel faktycznie zainfekowanych wśród k najwyżej sklasyfikowanych,
- **Recall@k** [40]: frakcja wszystkich zainfekowanych tabel odzyskanych w pierwszych k pozycjach rankingu,
- **Hits@k** [18]: liczba tabel zainfekowanych wśród k czołowych pozycji rankingu, podzielona przez mniejszą z wartości k i liczby wszystkich tabel zainfekowanych,
- **Brier score**: miara jakości kalibracji prawdopodobieństw, istotna dla detektora, który zwraca $p(\text{zainfekowana})$ jako wynik.

Metryki rankingowe są szczególnie istotne w warunkach nie zrównoważonych klas, charakterystycznych dla grafów rzadkich, gdzie liczba tabel czystych wielokrotnie przewyższa liczbę tabel zainfekowanych [6, 33]. Spośród wymienionych miar AUC-ROC jest w takich warunkach najbardziej optymistyczna, ponieważ pozostaje niewrażliwa na rozkład klas, przez co może sugerować dobrą skuteczność również wtedy, gdy bezwzględna liczba trafień w czołówce rankingu jest niewielka. Dlatego jako miarę uzupełniającą raportuje się AUC-PR, która wprost odzwierciedla udział klasy pozytywnej i w zadaniach nie zrównoważonych rozdziela metody wyraźniej niż AUC-ROC [15, 52]. Brier score [8], zdefiniowany jako średni kwadrat różnicy między oszacowanym prawdopodobieństwem a etykietą, jest natomiast jedyną ze stosowanych metryk oceniającą rzetelność samych oszacowań, a nie kolejność tabel w rankingu.

2.8 Systematyczny przegląd literatury

Stan wiedzy rozpoznano systematycznym przeglądem literatury (ang. *Systematic Literature Review*, SLR), przeprowadzonym zgodnie z wytycznymi Kitchenham i Chartersa [32]. Sekcja 2.8.1 opisuje protokół przeglądu i przebieg selekcji, a sekcje kolejne wyniki: omówienie prac wybranych do analizy pełnotekstowej oraz wynikającą z nich lukę badawczą.

Wynik przeglądu można streścić już tutaj. Wszystkie zidentyfikowane prace dotyczące broken lineage między obiektami bazy modelują problem jako predykcję krawędzi. Detekcji na poziomie węzłów, czyli wskazania, które tabele mają zerwany lineage, literatura ta nie podejmuje. Tę lukę wypełnia niniejsza praca. Omówione dalej prace pogrupowano w dwie kategorie: *bazowe*, na których niniejsza praca opiera się bezpośrednio (metoda kontrastowa oraz wykorzystany zbiór danych referencyjnych), oraz *metody pokrewne* odkrywania zależności lineage, które wyznaczają szerszy kontekst metodyczny.

2.8.1 Metodyka przeglądu

Strategia wyszukiwania

Wyszukiwanie przeprowadzono w bazie *DBLP Computer Science Bibliography*, uznanym źródle indeksującym recenzowane publikacje informatyczne, obejmującym zarówno czasopisma, jak i materiały konferencyjne. Ze względu na specyfikę tematu zapytanie ograniczono do dwóch terminów kluczowych, połączonych alternatywą, co zapewnia szerokie pokrycie dziedziny przy zachowaniu precyzji:

"data provenance"OR "data lineage"

Terminy te dobrano celowo szeroko. Węższe zapytanie, zawierające wprost frazę *broken lineage* lub *missing lineage*, pomijałoby prace opisujące to samo zjawisko innym słownictwem (np. *lineage reconstruction*, *provenance completion*). Ciężar selekcji przesunięto zatem z zapytania na etap przesiewania.

Kryteria selekcji

Zakres czasowy. Analizie poddano publikacje z lat 2022–2025. Ograniczenie to wynika z tempa rozwoju metod uczenia maszynowego w inżynierii danych. Prace wcześniejsze opisują w większości podejścia oparte na statycznej analizie schematów, nieprzystające do współczesnych architektur przetwarzania.

Kryteria włączenia. Publikacje w języku angielskim, proponujące konkretny algorytm lub architekturę możliwą do zaimplementowania i zweryfikowania eksperymentalnie.

Kryteria wyłączenia. Wyłączono prace spoza domeny inżynierii oprogramowania i baz danych, ponieważ termin *lineage* występuje licznie m.in. w biologii (*cell lineage tracing*). Pominęto również publikacje dotyczące wyłącznie wizualizacji grafów pochodzenia, bez wkładu algorytmicznego, a także prace skupione wyłącznie na aspektach bezpieczeństwa (szyfrowanie, blockchain), bez analizy struktury zależności między danymi.

Przebieg selekcji

Selekcję przeprowadzono dwuetapowo, najpierw na podstawie tytułów, a następnie abstraktów. Prace, które przeszły oba etapy, poddano analizie pełnotekstowej. Tabela 2.3 przedstawia liczby publikacji na poszczególnych etapach.

TABELA 2.3: Przebieg selekcji literatury w bazie DBLP dla zapytania "data provenance"OR "data lineage".

Etap	Zastosowane działanie	Publikacji
Wyniki surowe	Wyszukiwanie bez ograniczeń czasowych	1256
Filtrowanie	Lata 2022–2025, język angielski	288
Przesiewanie 1	Selekcja na podstawie tytułów	24
Przesiewanie 2	Selekcja na podstawie abstraktów	17
Wybór końcowy	Analiza pełnotekstowa	7

Największy ubytek następuje na etapie przesiewania tytułów (288 → 24) i wynika z wieloznaczności terminu *lineage* poza informatyką. Drugie przesiewanie (24 → 17) usunęło prace czysto teoretyczne oraz pozbawione opisu technicznego pozwalającego na odtworzenie metody. Analiza pełnotekstowa zawężyła zbiór do siedmiu prac reprezentujących odmienne podejścia algorytmiczne:

klasyczne uczenie maszynowe, analizę logów zapytań, grafowe sieci neuronowe, metody jądrowe oraz przetwarzanie zapytań rekurencyjnych i funkcji definiowanych przez użytkownika.

Uzupełnienie przeglądu o prace spoza bazy

Systematyczny przegląd przeprowadzono na początku prac nad pracą magisterską. W jego trakcie nie zostały uwzględnione trzy publikacje, które omówiono w dalszej części rozdziału: Dutkiewicz et al. [18], Andrzejewski et al. [3] oraz Brzeski i Roman [9]. Pochodzą one z lat 2025–2026 i w chwili wykonywania zapytania nie były jeszcze zaindeksowane w bazie DBLP. Dotarło do nich później, w drodze wyszukiwania ukierunkowanego oraz konsultacji z zespołem badawczym promotora. Uzupełnienie zbioru prac o pozycje wskazane przez ekspertów dziedzinowych jest praktyką dopuszczalną w przeglądach systematycznych [32], wymaga jednak jawnego zadeklarowania, gdyż prace te nie przeszły opisaną wyżej procedury selekcji. Wyznaczają one bezpośredni kontekst metodyczny, w którym plasuje się postawione pytanie badawcze.

2.8.2 Prace bazowe – metoda kontrastowa i zbiór danych

Leveraging machine learning techniques for discovering broken lineage links

Autorzy: Boiński, Andrzejewski, Grocholewski, Gruszczyński, Wrembel [6].

Problem badawczy. Ciągłość grafów *data lineage* ulega przerwaniu, gdy w potokach ETL wykorzystywane są obiekty pośrednie: tabele tymczasowe lub UDF. W rezultacie narzędzia klasy *data governance* tracą ślad przepływu danych i błędnie interpretują trwałą tabelę źródłową oraz tabelę docelową jako byty niezależne.

Zaproponowane rozwiązanie. Autorzy formułują problem rekonstrukcji przerwanych zależności jako binarną klasyfikację par obiektów bazodanowych, z inżynierią cech opartą na metadanych i podobieństwie nazw (Jaro–Winkler), klasyfikatorami Random Forest, RUSBoost, BalancedBagging i LightGBM oraz generowaniem etykiet metodą rekurencyjnego zastępowania tabel tymczasowych ich trwałymi źródłami. Ze względu na brak publicznych danych autorzy wygenerowali syntetyczne schematy baz LLM-ami.

Analiza krytyczna i relacja do pracy. Najwyższą skuteczność osiągnął RUSBoost ($F1 = 0,79$). Artykuł ten jest punktem wyjścia niniejszej pracy, różni się od niej jednak w dwóch zasadniczych punktach. Boiński et al. przewidują krawędzie i korzystają z semantyki nazw, podczas gdy w niniejszej pracy detekcja odbywa się na poziomie węzłów i wyłącznie na podstawie topologii (dane DLG-DG-23 są zanonimizowane). Adaptowano natomiast rodzinę klasyfikatorów (RF, RUSBoost, LightGBM) jako punkty odniesienia dla autorskiego detektora.

An open dataset of data lineage graphs

Autorzy: Chen, Zhao, Li, Zhang, Long, Zhou [11].

Problem badawczy. Rozwój metod w obszarze *data governance* jest ograniczany przez brak ogólnodostępnych, rzeczywistych zbiorów danych, ponieważ przedsiębiorstwa nie udostępniają grafów lineage ze względu na poufność.

Zaproponowane rozwiązanie. Autorzy opublikowali zbiór DLG-DG-23, pierwszy otwarty zestaw rzeczywistych grafów pochodzenia danych, obejmujący 18 grafów liczących od 278 do 17 085 węzłów, ze środowiska produkcyjnego Huawei Cloud (dane zanonimizowane), z węzłami trzech typów (tabela, zadanie, pole) i relacjami przepływu oraz hierarchii.

Analiza krytyczna i relacja do pracy. Wartość zbioru wynika z jego rzeczywistego, przemysłowego pochodzenia. Ograniczeniem jest niewielka liczba grafów oraz anonimizacja atrybutów.

W niniejszej pracy DLG-DG-23 jest referencyjnym zbiorem danych (*ground truth*) we wszystkich eksperymentach.

2.8.3 Metody pokrewne odkrywania zależności lineage

Data lineage discovery in databases based on knowledge graph link prediction

Autorzy: Dutkiewicz, Misiorek, Wrembel [18].

Problem badawczy. Automatyczne odkrywanie brakujących zależności lineage między obiektami bazy danych jest słabo zbadane, ponieważ rzeczywiste dane biznesowe i schematy baz nie są publicznie dostępne, a w konsekwencji brakuje benchmarków umożliwiających rzetelną ewaluację metod odkrywania.

Zaproponowane rozwiązanie. Praca wnosi trzy artefakty. Pierwszym jest procedura generowania scenariuszy broken lineage za pomocą frameworku opartego na LLM, obejmująca dziesięć typów scenariuszy (m.in. kopiowanie danych, transformacje, złączenia, deduplikację, widoki, zapytania rekurencyjne, partycjonowanie, tabele tymczasowe i funkcje tablicowe). Drugim jest model semantyczny transformujący scenariusze do grafu wiedzy (RDF, relacja *valueDerivedFrom* inspirowana ontologią PROV-O). Trzecim jest dostosowany do lineage protokół ewaluacji *w pełni indukcyjnej* predykcji krawędzi ($\mathcal{E}_{\text{train}} \cap \mathcal{E}_{\text{test}} = \emptyset$) z użyciem path-based GNN, próbkowaniem negatywów w proporcji 50:1 oraz metrykami AUC-ROC i Hits@10.

Analiza krytyczna i relacja do pracy. Wyniki są silnie zależne od typu scenariusza. Proste kopiowanie danych osiąga AUC-ROC 0,92 (model dedykowany), lecz scenariusze złożone spadają do $\approx 0,60$, a tabele tymczasowe, najczęstsza praktyczna przyczyna broken lineage, do AUC-ROC 0,49, czyli poziomu losowego. Potwierdza to trudność problemu nawet dla zaawansowanych metod grafowo-semantycznych. Z pracy tej zaadaptowano do niniejszej pracy *protokół indukcyjny cross-graph* oraz zestaw metryk rankingowych. Udostępniony przez autorów benchmark posłużył ponadto do zbudowania zewnętrznego grafu testowego DUT (sekcja 3.2.2). Zasadnicza różnica polega na tym, że Dutkiewicz et al. przewidują krawędzie w grafie wiedzy wzbogaconym semantycznie, podczas gdy niniejsza praca operuje na poziomie węzłów i czystej topologii.

On discovering provenance of data warehouse objects created by select-project queries

Autorzy: Andrzejewski, Boiński, Wrembel [3].

Problem badawczy. W hurtowniach danych obiekty (np. widoki zmaterializowane) powstają z innych obiektów przez zapytania select-project, a potoki integracji danych tworzą obiekty tymczasowe i ulotne (tabele tymczasowe, zmienne globalne, kursory), których zależności nie są automatycznie rejestrowane i zanikają po zakończeniu zadania.

Zaproponowane rozwiązanie. Autorzy proponują podejście analityczne, niewymagające uczenia maszynowego i złożone z dwóch algorytmów. Pierwszy odzyskuje współczynniki (nachylenie i wyraz wolny) funkcji liniowej zastosowanej w projekcji, a drugi odtwarza warunek selekcji użyty w zapytaniu. Zależność między obiektami jest wykrywana przez dopasowanie modelu matematycznego do wartości przechowywanych danych.

Analiza krytyczna i relacja do pracy. Metoda daje dokładne, interpretowalne wyniki, lecz jej założenia są restrykcyjne. Wymaga dostępu do zawartości tabel (wartości danych) i ogranicza się do transformacji liniowych w zapytaniach select-project. W warunkach niniejszej pracy (zanonimizowane grafy bez dostępu do danych i schematów) podejście to jest nieaplikowalne. Ograniczenie to uzasadnia postawione w niniejszej pracy pytanie o to, jak daleko sięga sygnał czysto topologiczny.

Inferring missing data lineage links from schema metadata using transformer-based models

Autorzy: Brzeski, Roman [9].

Problem badawczy. Istniejące metody ekstrakcji lineage (instrumentacja, analiza czasu wykonania, adnotowane potoki) zawodzą, gdy informacja o przepływie jest częściowo niedostępna, np. w środowiskach hybrydowych, systemach zastanych (*legacy*) lub przy audytach *post hoc*.

Zaproponowane rozwiązanie. Dwustopniowa metoda wnioskowania kierunkowych zależności lineage na poziomie kolumn wyłącznie z metadanych schematu, inspirowana technikami dopasowywania schematów. Bi-encoder transformerowy filtruje kandydatów, a cross-encoder wykonuje precyzyjną predykcję. Metodę oceniono na wielkoskalowych danych komercyjnych z ekstremalną nierównowagą klas (1 poprawny link na 90 000 par kandydackich).

Analiza krytyczna i relacja do pracy. Praca pokazuje, że przy dostępnej semantyce nazw kolumn i schematów modele transformerowe skutecznie odzyskują zależności mimo skrajnej nierównowagi klas. Warunkiem jest jednak dokładnie ta informacja, której w zbiorze DLG-DG-23 brak (identyfikatory UUID). Sygnał semantyczny i sygnał topologiczny badany w niniejszej pracy są zatem komplementarne, a ich połączenie stanowi naturalny kierunek dalszych badań.

2.8.4 Synteza porównawcza

Tabela 2.4 zestawia omówione prace według czterech wymiarów rozstrzygających o ich relacji do niniejszej pracy: poziomu, na którym formułowany jest problem, źródła wykorzystywanego sygnału, rodzaju danych ewaluacyjnych oraz zastosowanego protokołu oceny.

TABELA 2.4: Zestawienie porównawcze omówionych prac. Ostatni wiersz – niniejsza praca.

Praca	Poziom	Źródło sygnału	Dane	Protokół
Boiński et al. [6]	krawędź (para)	nazwy + metadane	syntetyczne (LLM)	klasyfikacja
Chen et al. [11]	— (zbiór danych)	—	rzeczywiste	—
Dutkiewicz et al. [18]	krawędź	graf wiedzy (RDF)	syntetyczne	indukcyjny
Andrzejewski et al. [3]	parametry zapytania	wartości danych	—	analityczny
Brzeski, Roman [9]	krawędź (kolumny)	metadane schematu	komercyjne	klasyfikacja
Psallidas et al. [50]	ekstrakcja	logi zapytań	rzeczywiste	—
Yamada et al. [60]	ekstrakcja (UDF)	analiza kodu	rzeczywiste	—
Dietrich et al. [17]	ekstrakcja (CTE)	przepisywanie zapytań	—	—
Kohan Marzagão et al. [33]	podobieństwo grafów	topologia	rzeczywiste	—
Shan et al. [55]	węzeł	heterogeniczny GNN	systemowe	—
Niniejsza praca	węzeł (tabela)	wyłącznie topologia	rzeczywiste	indukcyjny

W zestawieniu zwracają uwagę dwie prawidłowości. Kolumna „poziom” jest niemal w całości wypełniona wartością „krawędź” lub „ekstrakcja”. Jedyne podejście węzłowe to praca Shana et al. [55], dotycząca jednak systemowych grafów provenance w kontekście bezpieczeństwa, a nie obiektów bazodanowych. Żadna z prac operujących na lineage bazodanowym nie ogranicza się przy tym do sygnału czysto topologicznego. Wszystkie korzystają z nazw, metadanych schematu, wartości danych lub semantyki grafu wiedzy. Skrzyżowanie obu wymiarów, poziomu węzła i wyłącznej topologii, pozostaje niezajęte.

2.8.5 Luka badawcza

Omówione prace, od klasycznego uczenia maszynowego na cechach semantycznych i topologicznych [6], przez metody analityczne [3] i transformery na metadanych schematu [9], po indukcyjne GNN na grafach wiedzy [18], modelują broken lineage jako odtwarzanie zależności, czyli krawędzi

albo parametrów transformacji. Żadna nie stawia pytania, które tabele mają zerwany lineage. Niniejsza praca uzupełnia ten obraz, ponieważ wskazanie podejrzanych tabel może poprzedzać kosztowniejsze odtwarzanie konkretnych zależności.

2.8.6 Prace kontekstowe

Spośród pozostałych prac na uwagę zasługuje metoda *Provenance Graph Kernel* (PGK) [33], definiująca miary podobieństwa grafów proveniencji. Detekcja anomalii na poziomie węzłów pojawia się w pokrewnej dziedzinie systemowych grafów provenance i bezpieczeństwa (np. heterogeniczne GNN [55]), nie była jednak dotąd stosowana do lineage obiektów bazodanowych. Prace dotyczące proveniencji rekurencyjnych zapytań SQL [17], analizy logów [50] oraz UDF [60] tworzą szerszy kontekst literaturowy.

Rozdział 3

Problem i sposób jego rozwiązania

Rozdział precyzuje formalną definicję problemu detekcji węzłów o zerwanym lineage (sekcja 3.1). Sekcja 3.2 charakteryzuje wykorzystane dane, czyli zbiór DLG-DG-23 oraz zewnętrzny graf DUT wraz z adapterem, sekcja 3.3 opisuje metodykę symulacji broken lineage przez usuwanie zadań, a sekcja 3.4 architekturę potoku przetwarzania. Zaimplementowane metody detekcji omówiono w sekcji 3.5, realizację techniczną w sekcji 3.6, testy jednostkowe i odtwarzalność wyników w sekcji 3.7, a dostępność implementacji i pochodzenie algorytmów w sekcji 3.8.

3.1 Sformułowanie problemu

Graf lineage modeluje się jako skierowany graf DAG przepływu danych $G = (V, E)$, gdzie $V = V_J \cup V_T \cup V_F$ obejmuje węzły typu zadanie (*Data Job*), tabela (*Data Table*) i pole, a E zawiera krawędzie przepływu danych (*DATA_FLOW*) między zadaniami a tabelami. Zjawisko broken lineage odpowiada usunięciu z grafu pewnego zadania J . Tabele z nim incydentne, czyli jego poprzedniki (tabele karmiące J) oraz następniki (tabele karmione przez J), tracą część informacji o swoim pochodzeniu i stają się *zainfekowane* (ang. *infected*).

Obserwowany graf ma postać $G_{\text{obs}} = G \setminus \{J_1, \dots, J_m\}$, powstałą przez usunięcie podzbioru zadań. Zadaniem detekcji jest wyznaczenie funkcji, która każdej tabeli $t \in V_T$ przypisuje wynik $s(t) \in [0, 1]$ interpretowany jako oszacowane prawdopodobieństwo p (tabela t jest zainfekowana). Wynikiem nie jest decyzja binarna przy ustalonym progu, lecz ranking tabel. Tabele o najwyższym wyniku są pierwszymi kandydatami do ręcznej inspekcji.

Etykiety referencyjne (*ground truth*) generowane są automatycznie. Tabela jest zainfekowana wtedy i tylko wtedy, gdy była incydentna do co najmniej jednego usuniętego zadania. Zbiór kandydatów ograniczono do węzłów typu *Data Table*. Węzły typu pole (*field*) łączy z tabelami wyłącznie relacja *PARENT_CHILD*, dlatego nie podlegają one detekcji.

Zasadnicza trudność zadania polega na tym, że osierocona tabela-następnik po usunięciu zadania wygląda jak prawdziwa tabela źródłowa ($\text{in_df} = 0$). Rozróżnienie tych dwóch przypadków wymaga cech opisujących pozycję węzła w grafie DAG oraz uczenia indukcyjnego (cross-graph), a nie samego stopnia węzła.

3.2 Zbiory danych

W pracy wykorzystano dwa źródła danych o odmiennym pochodzeniu i przeznaczeniu. Wszystkie eksperymenty główne, obejmujące trening i ewaluację metod w protokole indukcyjnym, przeprowadzono na rzeczywistych grafach zbioru DLG-DG-23. Uzupełnieniem jest zewnętrzny graf DUT,

zbudowany na podstawie benchmarku Dutkiewicza et al. [18], który służy wyłącznie do sprawdzenia przenośności modeli wytrenowanych na DLG-DG-23. Oba źródła opisano w kolejnych podsekcjach.

3.2.1 Zbiór DLG-DG-23

Zbiór DLG-DG-23 pochodzi z pracy Chen et al. [11] i zawiera 18 grafów lineage pobranych ze środowiska produkcyjnego Huawei Cloud. Dane zostały zanonimizowane, a nazwy tabel i atrybutów zastąpiono identyfikatorami w formacie UUID. Schematów bazy danych nie udostępniono. Zbiór opublikowano w 2024 roku jako pierwszy otwarty zestaw rzeczywistych grafów lineage.

Każdy graf zawiera węzły trzech typów: *Data Job* (zapytanie SQL lub zadanie ETL), *Data Table* (tabela lub widok przechowujący dane) oraz *field* (atrybut lub kolumna należąca do tabeli). Łączą je krawędzie dwóch typów: *DATA_FLOW* (skierowana krawędź przepływu danych między tabelą a zadaniem) oraz *PARENT_CHILD* (relacja przynależności pola do tabeli). Pełny graf jest zatem *heterogeniczny*. Przedmiotem detekcji są wyłącznie węzły typu *Data Table*, a sygnał czerpany jest z podgrafu przepływu danych (krawędzie *DATA_FLOW* między węzłami *Data Table* i *Data Job*). Podgraf ten ma strukturę dwudzielną i skierowaną, interpretowaną jako graf DAG. Grafy różnią się skalą, a liczba węzłów waha się od 278 do 17 085.

Zbiór DLG-DG-23 wybrano, ponieważ jest pierwszym publicznie udostępnionym zestawem rzeczywistych grafów lineage [11], a w trakcie prowadzenia badań nie zidentyfikowano innego zbioru tego rodzaju. Anonimizacja nazw węzłów ma bezpośredni wpływ na dobór metod, ponieważ metryki podobieństwa oparte na nazwach obiektów (np. miara Jaro–Winklera stosowana przez Boińskiego et al. [6]) są nieaplikowalne. W niniejszej pracy sygnał ograniczono zatem do atrybutów topologicznych grafu. Ograniczenie to jest zarazem częścią pytania badawczego o to, czy sama struktura grafu lineage wystarcza do wskazania tabel o zerwanym pochodzeniu danych. Metoda skuteczna przy tak ograniczonym wglądzie w graf ma przy tym większą szansę na zastosowanie praktyczne niż podejścia wymagające pełnych metadanych.

Tabela 3.1 przedstawia statystyki poszczególnych grafów zbioru DLG-DG-23.

TABELA 3.1: Charakterystyka grafów zbioru DLG-DG-23.

ID	Węzły	Krawędzie DATA_FLOW	Skala
DLG1	298	24	mały
DLG2	464	37	mały
DLG3	603	57	mały
DLG4	415	32	mały
DLG5	1 299	175	średni
DLG6	13 840	1 443	duży
DLG7	574	43	mały
DLG8	546	34	mały
DLG9	756	62	mały
DLG10	5 378	497	duży
DLG11	2 024	121	średni
DLG12	5 645	469	duży
DLG13	2 157	229	średni
DLG14	453	24	mały
DLG15	558	41	mały
DLG16	5 574	745	duży
DLG17	651	38	mały
DLG18	17 085	1 694	duży

Skala: mały < 1 000 węzłów, średni 1 000–5 000, duży > 5 000.

3.2.2 Zewnętrzny graf DUT

Drugim źródłem danych jest benchmark opracowany przez Dutkiewicza et al. [18] w zespole badawczym promotora (sekcja 2.8). Obejmuje on syntetyczne scenariusze broken lineage, wygenerowane dla przykładowej bazy *Northwind* [43]. Lineage zapisany jest w nim na poziomie pojedynczych wierszy, w postaci grafu wiedzy RDF oraz plików CSV, w których każdy rekord wiąże wartość źródłową z wartością docelową, która z niej powstała. Jest to zatem reprezentacja drobnoziarnista (sekcja 2.1), niezgodna z gruboziarnistym modelem tabela–zadanie, na którym operują metody opisane w niniejszej pracy.

Aby ocenić na tych danych modele wytrenowane na DLG-DG-23 bez zmian w ich implementacji, opracowano adapter (moduł `dutkiewicz_adapter.py`), który agreguje zależności wierszowe do poziomu tabel. Dla każdej tabeli docelowej tworzony jest węzeł typu *Data Job*, do którego prowadzą krawędzie *DATA_FLOW* od wszystkich tabel źródłowych, z których pochodzą jej wiersze. Z węzła tego prowadzi następnie krawędź *DATA_FLOW* do samej tabeli docelowej. Kolumny kluczy występujące w zapisie lineage dodawane są jako węzły typu *field*, połączone z tabelą relacją *PARENT_CHILD*. Wynikowy graf ma te same typy węzłów i krawędzi co grafy DLG-DG-23, dzięki czemu przechodzi przez potok przetwarzania identycznie jak one.

Graf DUT liczy 21 tabel, 14 zadań i 33 krawędzie przepływu danych. Jest więc o rzędy wielkości mniejszy od grafów DLG-DG-23 i ma odmienną, łańcuchową topologię, w której tabele rzadko współdzielą zadania. Adapter nie odtwarza przy tym pełnych schematów tabel, ponieważ benchmark ich nie zawiera, dlatego liczba pól jest mniejsza niż w DLG-DG-23. Poprawność odwzorowania weryfikuje sześć testów jednostkowych (tabela 3.5). Graf DUT nie jest wykorzystywany w treningu żadnej z metod, a wyniki uzyskane na nim przedstawiono w sekcji 4.9.

3.3 Metodyka symulacji broken lineage przez usuwanie zadań

Ponieważ zbiór DLG-DG-23 zawiera w pełni zaobserwowane grafy lineage, zjawisko broken lineage symulowane jest przez kontrolowane usuwanie zadań (nie pojedynczych krawędzi). Podejście to odwzorowuje przyczynę broken lineage, ponieważ zniknięcie tabeli tymczasowej lub ukrycie logiki przez UDF odpowiada utracie całego węzła-zadania wraz z jego krawędziami.

3.3.1 Procedura symulacji i konstrukcja etykiet

Kandydatami do usunięcia są *zadania łączące*, czyli zadania mające co najmniej jedną wejściową i jedną wyjściową krawędź *DATA_FLOW* ($\text{in_df} > 0 \wedge \text{out_df} > 0$). Usunięcie takiego zadania zrywa lineage po obu stronach, ponieważ tabele karmiące je tracą konsumenta, a tabele przez nie karmione tracą producenta.

Instancję klasyfikacji węzłów buduje się z grafu G w kilku krokach. Najpierw losowany jest podzbiór zadań łączących przeznaczonych do usunięcia, którego udział reguluje parametr `removal_ratio`. W eksperymentach przyjęto wartość 10%, a wpływ tego parametru zbadano w analizie wrażliwości (sekcja 4.6). Zbiór tabel zainfekowanych wyznacza się jako sumę tabel incydentnych do usuniętych zadań. Graf obserwowany G_{obs} powstaje następnie przez usunięcie wybranych zadań wraz z ich krawędziami. Kandydatami do detekcji są wszystkie tabele pozostałe w G_{obs} , przy czym etykieta 1 oznacza tabelę zainfekowaną, a etykieta 0 tabelę czystą.

Dodatkowo zaimplementowano wariant kontrolny, w którym każda instancja usuwa dokładnie jedno zadanie, co daje czystą interpretację przyczynową (jedno zdarzenie broken lineage = jedno brakujące zadanie).

3.3.2 Kontrola przecieku – wykluczenie węzłów izolowanych

Usunięcie zadania może pozbawić tabelę wszystkich krawędzi przepływu danych ($in_df = 0 \wedge out_df = 0$). Ponieważ w oryginalnych grafach tabele izolowane nie występują, trywialna reguła „tabela izolowana $\Rightarrow$ zainfekowana” pozwala rozpoznać znaczną część pozytywów bez żadnego uczenia i sztucznie zawyża wynik. Aby zapewnić uczciwą ewaluację, wprowadzono flagę `exclude_isolated`, która usuwa z puli kandydatów tabele w pełni izolowane. Wariant ten stawia trudniejsze i bardziej realistyczne zadanie, polegające na wykryciu tabel o częściowo zerwanym lineage, które nadal mają część połączeń. W pracy raportowane są oba warianty, a wariant uczciwy (z wykluczeniem izolowanych) traktowany jest jako główny.

Tabela 3.2 przedstawia skalę symulacji dla czterech wartości parametru `removal_ratio`. Łącznie w 18 grafach zbioru DLG-DG-23 znajduje się 1453 zadania łączące (od 3 do 404 na graf), spośród których usuwana jest losowa część. Liczby podano dla wariantu przed wykluczeniem tabel izolowanych, ponieważ tylko wtedy można zmierzyć ich udział wśród pozytywów.

TABELA 3.2: Charakterystyka symulacji broken lineage w zależności od parametru `removal_ratio`. Wartości uśrednione po 18 grafach i trzech ziarnach losowości (42–44). W ostatniej kolumnie podano odsetek tabel zainfekowanych, które utraciły wszystkie krawędzie przepływu danych i są rozpoznawalne trywialną regułą izolacji.


<code>removal_ratio</code>	Usuniętych zadań	Tabel zainfekowanych	Udział pozytywów	Pozytywów izolowanych
0,05	4,2	15,1	11,4%	19,7%
0,10	8,0	25,1	19,0%	22,9%
0,20	16,2	45,2	34,1%	29,8%
0,30	24,3	62,6	47,3%	34,5%

Dwie obserwacje z tabeli mają znaczenie dla konstrukcji eksperymentu. Przyjęta w biegu kanonicznym wartość 0,10 daje średnio 25 tabel zainfekowanych na graf przy 19% pozytywów. Zadanie pozostaje więc wyraźnie nie zrównoważone, ale klasa pozytywna jest dostatecznie liczna, by metryki rankingowe były wiarygodne. Udział pozytywów trywialnych (tabel w pełni izolowanych) rośnie z kolei z 19,7% do 34,5% wraz ze wzrostem odsetka usuwanych zadań. Im silniejsze zaburzenie, tym większa część zadania daje się rozwiązać bez żadnego uczenia. Liczby te określają skalę przecieku, któremu zapobiega opisana wyżej flaga `exclude_isolated`. Przy biegu kanonicznym usuwa ona z puli kandydatów blisko jedną czwartą pozytywów, i to tych najłatwiejszych.

3.4 Architektura rozwiązania

Potok przetwarzania składa się z czterech komponentów: modułu wczytywania grafów (wraz z adapterem grafu DUT), modułu symulacji broken lineage (budowa instancji klasyfikacji węzłów), metod detekcji oraz modułu ewaluacji indukcyjnej.

Rysunek 3.1 przedstawia schemat potoku przetwarzania, od wczytania grafów, przez symulację broken lineage i ekstrakcję cech, po scoring detektora i wyznaczenie metryk rankingowych. Oba źródła danych trafiają do wspólnego potoku. Grafy DLG-DG-23 wczytywane są bezpośrednio z plików JSON, natomiast graf DUT przechodzi najpierw przez adapter, który sprowadza go do tego samego modelu danych. Od etapu symulacji oba rodzaje grafów przetwarzane są identycznie, różni je jedynie rola w ewaluacji.



*DLG-DG-23: protokół indukcyjny leave-one-graph-out (trening na 17 grafach, test na 1)
DUT: wyłącznie test modeli wytrenowanych na DLG-DG-23*

RYSUNEK 3.1: Schemat potoku przetwarzania. Grafy DLG-DG-23 oceniane są w protokole indukcyjnym leave-one-graph-out (trening na 17 grafach, test na grafie niewidzianym). Graf DUT, sprowadzony adapterem do modelu tabela-zadanie, służy wyłącznie do testu modeli wytrenowanych na DLG-DG-23.

3.4.1 Moduł wczytywania danych

Dane wejściowe każdego grafu przechowywane są w dwóch plikach JSON: `DLGi-node.json` (opisy węzłów z atrybutem `asset_type`) oraz `DLGi-edge.json` (krawędzie z atrybutami `relation_type` i `relation_id`). Moduł `loader.py` buduje z nich obiekt `nx.DiGraph` (NetworkX) i zwraca słownik wszystkich 18 grafów. Graf DUT wczytywany jest przez moduł `dutkiewicz_adapter.py`, który zwraca obiekt tego samego typu, z atrybutami węzłów i krawędzi zgodnymi z konwencją DLG-DG-23 (sekcja 3.2.2). Dalsze moduły potoku nie rozróżniają więc źródła grafu.

3.4.2 Moduł symulacji usuwania zadań

Moduł `job_removal.py` realizuje metodykę z sekcji 3.3: identyfikuje zadania łączące, usuwa ich podzbiór, wyznacza zbiór zainfekowanych tabel i zwraca instancję (graf G_{obs} , listę kandydatów, etykiety, listę usuniętych zadań). Obsługuje warianty `side`, określający stronę incydencji, po której tabele uznaje się za zainfekowane (strona producenta, konsumenta lub obie), oraz `exclude_isolated`. Funkcja `inductive_split` dzieli identyfikatory grafów na rozłączne zbiory treningowy i testowy (cross-graph).

3.4.3 Moduł ewaluacji i metryki rankingowe

Moduł `node_metrics.py` wyznacza metryki rankingowe: AUC-ROC, AUC-PR, Precision@k, Recall@k, Hits@k oraz Brier score. Wyniki agregowane są po grafach testowych w protokole indukcyjnym. Dla stabilności oszacowań stosuje się powtórzenia z różnymi ziarnami i trzymowanie wartości skrajnych (min/max).

Ewaluację prowadzi się w protokole indukcyjnym cross-graph. Model trenuje się na podzbiorze grafów, a testuje na grafach niewidzianych (leave-one-graph-out lub podział zbioru 18 grafów).

Zbiory treningowy i testowy są rozłączne, co sprawdza zdolność metody do generalizacji na nowe grafy, a nie jedynie do zapamiętania jednego. Konsekwencją tego protokołu jest wykluczenie metody Node2Vec [22], która uczy zanurzeń węzłów transduktywnie, dla konkretnego grafu, przez co embeddingi są geometrycznie nieporównywalne między grafami [24]. Obserwacja ta motywuje zastosowanie indukcyjnych grafowych sieci neuronowych (GraphSAGE [24], R-GCN [53], HGT [28]), wskazanych w rozdziale 5 jako kierunek dalszych badań.

3.5 Zaimplementowane metody detekcji

Zaimplementowano trzy grupy metod detekcji zainfekowanych tabel, różniące się ilością wykorzystywanej informacji i stopniem złożoności. Heurystyki strukturalne (sekcja 3.5.1) przypisują tabeli wynik na podstawie prostych reguł i nie wymagają uczenia, dlatego wyznaczają dolny punkt odniesienia. Klasyczne klasyfikatory uczenia maszynowego (sekcja 3.5.2) uczą się na grafach treningowych zależności między wektorem cech topologicznych a etykietą, co pozwala ocenić, ile wnosi samo uczenie indukcyjne. Autorski detektor LineageDetector (sekcja 3.5.3) rozszerza ten wektor o relacyjny score kompletności i uzupełnia model o kalibrację prawdopodobieństw.

Wszystkie metody mają wspólny interfejs. Dla każdej tabeli-kandydata zwracają wynik z przedziału $[0, 1]$, na podstawie którego budowany jest ranking. Dzięki temu każda z nich jest oceniana w tym samym potoku, na tych samych instancjach i tymi samymi metrykami, a różnice wyników można przypisać samym metodom.

3.5.1 Heurystyki strukturalne

Heurystyki strukturalne przypisują tabeli wynik podejrzliwości wyłącznie na podstawie jej pozycji w grafie, bez etapu uczenia. Są naturalnym punktem odniesienia (*baseline*) dla metod uczonych. Miary oparte na wspólnych sąsiadach (Common Neighbors, Jaccard, Adamic-Adar) [38] są w grafie dwudzielnym nieskuteczne, ponieważ węzły tego samego typu nigdy nie mają wspólnych sąsiadów bezpośrednich. Z tego powodu wykluczono je z implementacji.

W pracy zaimplementowano cztery heurystyki bazowe. Piątym punktem odniesienia w tej grupie jest sam *score kompletności* (sekcja 3.5.3), oceniany dodatkowo w oderwaniu od detektora, co pozwala rozdzielić wkład sygnału relacyjnego od wkładu uczenia. W zestawieniach rozdziału 4 występuje on zatem jako osobna metoda obok czterech poniższych:

- **Anomalia stopnia** (*degree_anomaly*): wynik $1/(1 + \deg(t))$, gdzie $\deg(t)$ jest stopniem całkowitym tabeli. Heurystyka opiera się na założeniu, że tabela, która utraciła zadanie, ma mniej połączeń niż przed zerwaniem lineage.
- **Brzeg grafu** (*boundary*): suma wskaźników $1[\text{in_df} = 0] + 1[\text{out_df} = 0]$. Tabele na brzegu przepływu (korzenie i liście) są podejrzane, ponieważ zerwanie lineage często przesuwają na brzeg grafu.
- **Niska łączność z zadaniami** (*low_job_connectivity*): wynik $1/(1 + n_J(t))$, gdzie $n_J(t)$ to liczba unikatowych zadań sąsiadujących z tabelą przez krawędzie *DATA_FLOW*.
- **Reguła korzenia** (*rule_root*): binarny wskaźnik $1[\text{in_df} = 0]$, zgodnie z którym każda tabela bez producenta jest uznawana za podejrzaną. To celowo trywialny punkt odniesienia, obrazujący siłę najprostszego możliwego symptomu.

Heurystyki te mierzą wyłącznie lokalny symptom (stopień, rola). Ich ograniczenie, przede wszystkim nieodróżnianie osieroconej tabeli od prawdziwego źródła, motywuje metody uczone

oraz autorski detektor LineageDetector (sekcja 3.5.3), który wzbogaca opis węzła o relacyjny score kompletności (peer-consistency).

3.5.2 Klasyczne metody uczenia maszynowego

Klasyczne metody ML traktują detekcję jako binarną klasyfikację węzła, w której wejściem jest wektor cech opisujących pozycję tabeli w grafie DAG, a wyjściem prawdopodobieństwo zainfekowania. Ze względu na anonimizację (UUID) jako cechy przyjęto wyłącznie atrybuty topologiczne, ponieważ metryki oparte na nazwach są nieaplikowalne.

Wektor cech węzła

Tabela 3.3 przedstawia pełny wektor 13 cech topologicznych wyznaczanych dla każdej tabeli-kandydata. Cechy opisują pozycję węzła w grafie przepływu danych, bo to ona, a nie sam stopień, pozwala odróżnić prawdziwą tabelę źródłową od tabeli osieroconej po usunięciu zadania.

TABELA 3.3: Wektor cech topologicznych węzła (moduł `node_features`).

Nr	Cecha	Opis	Rola w detekcji
1	<code>in_df</code>	Liczba wejściowych krawędzi <code>DATA_</code> <code>FLOW</code> (od zadań)	Brak producenta (= 0) to główny symptom zerwania
2	<code>out_df</code>	Liczba wyjściowych krawędzi <code>DATA_</code> <code>FLOW</code> (do zadań)	Symetryczny symptom, czyli utrata konsumenta
3	<code>degree</code>	Stopień całkowity węzła (wszystkie typy krawędzi)	Ogólna łączność, spadająca po usunięciu zadania
4	<code>role</code>	Rola w przepływie (źródło, pośrednia, ujście, poza przepływem)	Pozycja funkcjonalna tabeli w DAG
5	<code>flow_depth</code>	Głębokość w DAG (odległość od źródeł)	Osierocona tabela ma sztucznie małą głębokość
6	<code>flow_reach</code>	Zasięg w dół DAG (odległość do ujść)	Symetrycznie sztucznie mały zasięg
7	<code>depth_plus_reach</code>	Suma głębokości i zasięgu	Długość ścieżki przez węzeł, wykrywa „skrótowe” łańcuchy
8	<code>is_root</code>	Wskaźnik <code>1[in_df = 0]</code>	Binarna wersja symptomu utraty producenta
9	<code>is_leaf</code>	Wskaźnik <code>1[out_df = 0]</code>	Binarna wersja symptomu utraty konsumenta
10	<code>n_field_children</code>	Liczba pól tabeli (krawędzie <code>PARENT_</code> <code>CHILD</code>)	Rozmiar tabeli, sygnał niezależny od przepływu
11	<code>n_job_neighbors</code>	Liczba unikatowych zadań sąsiadujących	Łączność z warstwą zadań
12	<code>avg_job_in_df</code>	Średni stopień wejściowy sąsiednich zadań	Charakterystyka otoczenia węzła
13	<code>avg_job_out_df</code>	Średni stopień wyjściowy sąsiednich zadań	Jak wyżej, od strony wyjść

Detektor LineageDetector (sekcja 3.5.3) rozszerza ten wektor o trzy cechy kompletności (`peer_producer_score`, `peer_consumer_score`, `completeness_anomaly`), opisane w sekcji 3.5.3.

Random Forest

Random Forest (RF) [7] to metoda uczenia zespołowego oparta na uśrednianiu predykcji drzew decyzyjnych trenowanych na losowych podpróbkach danych i cech (*bagging*). Dla obsługi niezrównoważonych klas zastosowano `class_weight="balanced"`.

RUSBoost

RUSBoost (*Random Under-Sampling Boosting*) [54] łączy boosting AdaBoost z losowym podpróbkowaniem klasy większościowej przed każdą iteracją. Zaimplementowano go dla bezpośredniego nawiązania do wyników Boińskiego et al. [6], przy czym w niniejszej pracy klasyfikuje on węzły, a nie pary obiektów.

LightGBM

LightGBM [31] to implementacja gradientowego boostingu drzew decyzyjnych, budująca kolejne drzewa sekwencyjnie, każde minimalizując błąd reszkowy poprzednika. Niezbalansowanie klas kompensuje parametr `class_weight = balanced`, przypisujący obserwacjom wagi odwrotnie proporcjonalne do liczności klasy.

3.5.3 Autorski detektor LineageDetector

Autorski detektor `LineageDetector` (klasa `LineageHealthDetector`) łączy w jednym skalibrowanym modelu trzy elementy. Podstawę stanowią cechy pozycji w DAG, wyznaczone przez moduł `node_features` i opisujące węzeł lokalnie. Uzupełnia je score kompletności *peer-consistency*, opisany w dalszej części sekcji, który wnosi sygnał relacyjny i stanowi główny element wkładu własnego pracy. Całość zamyka kalibracja prawdopodobieństw metodą izotoniczną (`CalibratedClassifierCV`), dzięki której wynik detektora można interpretować jako oszacowanie $p(\text{zainfekowana})$, a nie jedynie jako wartość porządkującą ranking.

Score kompletności peer-consistency

Zaproponowany w pracy score kompletności opiera się na założeniu, że tabela o zerwanym lineage jest *strukturalnie niespójna* ze swoimi sąsiadami (peerami) w grafie DAG. Dla tabeli-korzenia (`in_df = 0`) rozważa się zbiór peerów-wejść, czyli inne tabele wpadające do tych samych zadań downstream. Jeśli peerzy mają producenta, a rozpatrywana tabela nie, to jej brak producenta jest podejrzany, ponieważ prawdziwe źródło danych sąsiaduje zwykle z innymi źródłami. Symetrycznie dla tabeli-liścia (`out_df = 0`) i jej peerów po stronie konsumpcji. Formalnie dla tabeli t definiuje się:

$$\text{prod}(t) = \frac{1}{|P(t)|} \sum_{p \in P(t)} \mathbf{1}[\text{in_df}(p) > 0], \quad \text{cons}(t) = \frac{1}{|C(t)|} \sum_{p \in C(t)} \mathbf{1}[\text{out_df}(p) > 0],$$

gdzie $P(t)$ i $C(t)$ oznaczają zbiory peerów odpowiednio po stronie producenta i konsumenta, a $\mathbf{1}[\cdot]$ funkcję wskaźnikową. Bramkowany sygnał anomalii aktywuje się wyłącznie na brzegu grafu:

$$\text{anomaly}(t) = \max(\mathbf{1}[\text{in_df}(t) = 0] \cdot \text{prod}(t), \mathbf{1}[\text{out_df}(t) = 0] \cdot \text{cons}(t)).$$

Sygnał ten ma charakter relacyjny. Różni się jakościowo od lokalnego stopnia węzła i dostarcza informacji niedostępnej klasyfikatorowi korzystającemu wyłącznie z cech lokalnych. Definicja jest symetryczna względem obu stron przepływu, jednak na zbiorze DLG-DG-23 aktywna okazuje się wyłącznie strona producenta, ponieważ każde zadanie w tym zbiorze zapisuje dokładnie jedną tabelę, przez co zbiór $C(t)$ jest zawsze pusty. Konsekwencje tej własności omówiono w sekcji 4.7. Trzy wynikające z niego cechy (`peer_producer_score`, `peer_consumer_score`, `completeness_anomaly`) rozszerzają wektor cech z tabeli 3.3 i są dostępne wyłącznie detektorowi `LineageDetector`.

Bazowym estymatorem jest domyślnie Random Forest, a wariantem alternatywnym LightGBM. Interfejs `fit/score` jest zgodny z pozostałymi klasyfikatorami, co umożliwia bezpośrednie porównanie w tym samym potoku. Konstrukcja detektora umożliwia badania ablacyjne. Wyłączenie

kalibracji (`calibrate=False`) izoluje jej wpływ na Brier score, a wyłączenie cech kompletności (`use_completeness=False`) wpływ sygnału relacyjnego na AUC.

3.6 Implementacja

Sekcja opisuje realizację techniczną potoku z sekcji 3.4: zastosowane narzędzia, organizację kodu oraz te fragmenty implementacji, które są istotne dla zrozumienia metody, a nie wynikają wprost z jej opisu formalnego.

3.6.1 Stos technologiczny

Całość zaimplementowano w języku Python. Tabela 3.4 zestawia wykorzystane biblioteki wraz z wersjami, w których wykonano bieg kanoniczny. Podanie wersji jest istotne dla odtwarzalności, ponieważ implementacje algorytmów uczenia maszynowego bywają modyfikowane między wydaniem, co może wpływać na wyniki liczbowe.

TABELA 3.4: Stos technologiczny i wersje bibliotek użyte w biegu kanonicznym.

Skłladnik	Wersja	Rola w pracy
Python [51]	3.10.2	Środowisko uruchomieniowe
NetworkX [23]	3.4.2	Reprezentacja i przetwarzanie grafów
NumPy [25]	1.26.4	Operacje macierzowe, wektory cech
pandas [42]	1.5.1	Agregacja wyników, eksport CSV
scikit-learn [48]	1.6.1	Random Forest, kalibracja izotoniczna, metryki
LightGBM [31]	4.6.0	Gradientowy boosting drzew
imbalanced-learn [37]	0.14.1	RUSBoost
SciPy [57]	1.15.3	Test kolejności par Wilcoxona
Matplotlib [29]	3.8.0	Rysunki
pytest [35]	9.0.2	Testy jednostkowe

3.6.2 Organizacja repozytorium

Kod podzielono na pakiety odpowiadające etapom potoku, a skrypty uruchomieniowe oddzielono od modułów bibliotecznych, aby każdy eksperyment z rozdziału 4 dawał się odtworzyć jednym poleceniem. Listing 3.1 przedstawia strukturę katalogów.

3.6.3 Format danych i wczytywanie

Każdy graf zbioru DLG-DG-23 opisany jest parą plików JSON: lista węzłów z atrybutem `asset_type` oraz lista krawędzi z atrybutami `relation_id` i `relation_type` (listing 3.2). Moduł `loader.py` przekształca je w obiekt `nx.DiGraph` i przenosi typ węzła oraz typ relacji do atrybutów grafu. Dzięki temu pozostałe moduły filtrują podgraf przepływu danych bez ponownego sięgania do plików.

```

src/
  data/
    loader.py          # wczytanie 18 grafow DLG-DG-23 z JSON
    dutkiewicz_adapter.py # adapter benchmarku zewnetrznego (graf DUT)
  detection/
    job_removal.py      # symulacja broken lineage, etykiety, podzial
    node_features.py    # 13 cech topologicznych wezla
    completeness.py    # score peer-consistency (wkład własny)
    lineage_detector.py # LineageHealthDetector
    node_classifier.py  # heurystyki + klasyczne klasyfikatory
    node_metrics.py     # metryki rankingowe
    run_detection_experiments.py # bieg kanoniczny (rozdz. 4.2)
    run_ablation.py     # badanie ablacyjne (rozdz. 4.5)
    run_cross_dataset.py # test cross-dataset (rozdz. 4.9)
    run_removal_sensitivity.py # analiza wzrazliwosci (rozdz. 4.6)
  scripts/
    test_istotnosci.py  # testy Wilcoxona (rozdz. 4.4)
    tabela_symulacji.py # tabela charakterystyki symulacji
  tests/               # 83 testy jednostkowe (pytest)
  results/             # wyniki biegow w formacie CSV

```

LISTING 3.1: Struktura repozytorium (fragmenty istotne dla detekcji węzłów).

```

// DLG1-node.json
{"nodes": [
  {"asset_id": "3f2a...c81", "asset_type": "Data Table"},
  {"asset_id": "9b07...4de", "asset_type": "Data Job"},
  {"asset_id": "a154...77f", "asset_type": "Data Field"}
]}

// DLG1-edge.json
{"edges": [
  {"relation_id": "r-0012", "relation_type": "DATA_FLOW",
   "source": "3f2a...c81", "target": "9b07...4de"},
  {"relation_id": "r-0013", "relation_type": "PARENT_CHILD",
   "source": "3f2a...c81", "target": "a154...77f"}
]}

```

LISTING 3.2: Fragment plików wejściowych DLGi-node.json i DLGi-edge.json (identyfikatory skrócone).

3.6.4 Wyznaczanie score'u peer-consistency

Najistotniejszym fragmentem implementacji jest wyznaczanie relacyjnego score'u kompletności, zdefiniowanego wzorami w sekcji 3.5.3. Listing 3.3 pokazuje jego rdzeń. Sam wzór nie precyzuje, że zbiory peerów budowane są przez zadania. Peerami tabeli po stronie producenta są inne tabele wpadające do tych samych zadań downstream, w grafie dwudzielnym nie istnieje bowiem bezpośrednia krawędź tabela–tabela. Widoczne w listingu bramkowanie wskaźnikami odpowiada wprost drugiemu ze wzorów z sekcji 3.5.3. Bez niego score mierzyłby jedynie własności otoczenia, a nie niespójność tabeli z jej otoczeniem.

```

1 # Strona producenta: peerzy = inne wejścia do downstream-jobow tej tabeli.
2 downstream_jobs = [v for _, v, d in G.out_edges(t, data=True)
3                     if d.get("relation_type") == "DATA_FLOW"
4                     and G.nodes[v].get("asset_type") == "Data_Job"]
5 prod_peers = set()
6 for j in downstream_jobs:
7     prod_peers.update(job_inputs.get(j, ()))
8 prod_peers.discard(t)
9 prod_score = (np.mean([1.0 if in_df[p] > 0 else 0.0 for p in prod_peers])
10              if prod_peers else 0.0)
11
12 # Bramkowana anomalia: liczy się tylko na brzegu (korzen/lisc).
13 anomaly = 0.0
14 if in_df[t] == 0:
15     anomaly = max(anomaly, prod_score)
16 if out_df[t] == 0:
17     anomaly = max(anomaly, cons_score)

```

LISTING 3.3: Rdzeń wyznaczania score'u peer-consistency (moduł `completeness.py`).

3.6.5 Protokół indukcyjny w kodzie

Pętla ewaluacji realizuje schemat leave-one-graph-out, w którym dla każdego grafu testowego model uczy się na wszystkich pozostałych. Listing 3.4 przedstawia jej szkielet. Kluczowa dla poprawności protokołu jest kolejność operacji. Instancje wszystkich grafów budowane są przed pętlą, przy wspólnym ziarnie, a pula treningowa powstaje przez wykluczenie grafu testowego z gotowego słownika. Model nie ma więc dostępu do żadnej informacji z grafu testowego, także pośrednio przez dobór usuwanych zadań.

```

1 datasets = build_datasets(graphs, removal_ratio, seed, side,
2                           exclude_isolated=exclude_isolated)
3 for test_g in datasets:
4     ds_test = datasets[test_g]
5     train_pool = [datasets[g] for g in datasets if g != test_g]
6
7     for name in FIT_MODELS:
8         clf = _make_model(name, seed).fit(train_pool)
9         m = node_detection_metrics(ds_test["labels"], clf.score(ds_test))
10        rows.append({"graph": test_g, "algorithm": name, **m})

```

LISTING 3.4: Szkielet pętli leave-one-graph-out (moduł `run_detection_experiments.py`).

Wyniki z kolejnych ziaren agregowane są średnią z trymowaniem wartości skrajnych (odrzućenie najmniejszej i największej), co ogranicza wpływ pojedynczego nietypowego losowania na oszacowanie.

3.6.6 Złożoność obliczeniowa

Koszt przetwarzania jednego grafu jest liniowy względem liczby krawędzi. Wyznaczenie stopni *DATA_FLOW*, ekstrakcja cech oraz budowa zbiorów peerów wymagają stałej liczby przejść po krawędziach, a metadane przepływu (głębokość i zasięg w DAG) wyznaczone są przeszukiwaniem grafu, również w czasie $O(|V| + |E|)$. Dominującym składnikiem kosztu nie jest zatem przetwarzanie grafu, lecz trenowanie klasyfikatorów. W protokole leave-one-graph-out model uczony jest od nowa dla każdego grafu testowego, co przy 18 grafach, trzech ziarnach i czterech wariantach detektora daje 216 pełnych treningów. Bieg ablacyjny z sekcji 4.5 zajął z tego powodu 412 sekund, podczas

gdy sama ekstrakcja cech dla wszystkich 18 grafów trwa poniżej sekundy. Skala zbioru DLG-DG-23 (do 17 085 węzłów na graf) nie stanowi więc ograniczenia wydajnościowego.

3.7 Testy jednostkowe i odtwarzalność

3.7.1 Zakres testów

Poprawność implementacji zweryfikowano zestawem 83 testów jednostkowych uruchamianych narzędziem `pytest`. W wersji implementacji opisanej w pracy wszystkie testy kończą się powodzeniem. Tabela 3.5 przedstawia ich rozkład na moduły.

Poza poprawnością techniczną testy sprawdzają dwie własności istotne metodycznie. Pierwszą jest brak przecieku między zbiorem treningowym a testowym, weryfikowany przez sprawdzenie, czy identyfikatory grafów w obu zbiorach są rozłączne. Drugą jest determinizm symulacji, który oznacza, że przy ustalonym ziarnie losowości powtórne wykonanie daje identyczny zbiór usuniętych zadań i identyczne etykiety. Bez tej własności liczby raportowane w rozdziale 4 nie byłyby odtwarzalne.

TABELA 3.5: Rozkład testów jednostkowych na moduły.

Plik testowy	Liczba	Weryfikowane własności
<code>test_loader.py</code>	29	Poprawność typów węzłów i krawędzi, zgodność liczby obiektów z plikami źródłowymi, wczytanie wszystkich 18 grafów
<code>test_splitter.py</code>	17	Rozłączność podziałów, zgodność licznosci podzbiorów
<code>test_job_removal.py</code>	12	Identyfikacja zadań łączących, poprawność etykiet, rozłączność zbiorów treningowego i testowego, działanie flagi <code>exclude_isolated</code>
<code>test_scenario_splitter.py</code>	9	Scenariusze usuwania krawędzi (badanie wstępne)
<code>test_dutkiewicz_adapter.py</code>	6	Mapowanie benchmarku Dutkiewicza et al. na model tabela–zadanie– <i>DATA_FLOW</i> (graf DUT)
<code>test_node_features.py</code>	4	Wymiar wektora cech, zgodność z <code>feature_names()</code> , wartości brzegowe dla węzłów izolowanych
<code>test_completeness.py</code>	3	Poprawność <code>score</code> 'u peer-consistency, brankowanie sygnału anomalii
<code>test_lineage_detector.py</code>	3	Interfejs <code>fit/score</code> , zakres zwracanych prawdopodobieństw, warianty ablacyjne
Razem	83	

3.7.2 Odtwarzalność wyników

Wszystkie liczby przedstawione w rozdziale 4 pochodzą z jednego *biegu kanonicznego* o ustalonej konfiguracji: 18 grafów, `removal_ratio = 0,10`, `side = both`, trzy powtórzenia z ziarnami 42–44, protokół indukcyjny `leave-one-graph-out`, próg wiarygodności `MIN_POS = 5`, wariant uczciwy (`exclude_isolated`). Wyniki pośrednie zapisywane są w postaci plików CSV w katalogu `results/`, osobno dla wariantu uczciwego i zawyżonego, wraz z opisem konfiguracji. Eksperymenty poboczne (ablacja, analiza wrażliwości, test `cross-dataset`) mają własne skrypty i własne pliki wynikowe, wymienione w listingu 3.1, co pozwala odtworzyć każdą tabelę rozdziału 4 niezależnie od pozostałych.

3.8 Dostępność implementacji i pochodzenie algorytmów

Całość implementacji opisanej w niniejszej pracy, obejmującą moduły wczytywania danych, symulacji broken lineage, ekstrakcji cech, metod detekcji oraz ewaluacji, wraz z testami jednostkowymi i skryptami odtwarzającymi eksperymenty z rozdziału 4, udostępniono w publicznym repozytorium Git pod adresem <https://github.com/Catcuss/magisterka-data-lineage> (dostęp zweryfikowano 19 sierpnia 2026 r.). Repozytorium zawiera instrukcję uruchomienia (dodatek A) oraz pliki konfiguracyjne biegu kanonicznego, co zapewnia odtwarzalność raportowanych wyników.

Metody z grupy heurystyk oraz klasyczne klasyfikatory nie są oryginalnym wkładem pracy, lecz stanowią punkty odniesienia (*baseline*) zaczerpnięte z literatury i z publicznych bibliotek. Wkładem własnym jest ich adaptacja do zadania detekcji zainfekowanych węzłów w grafie lineage, autorski detektor LineageDetector oraz adapter grafu DUT. Pochodzenie i zakres adaptacji poszczególnych składników zestawiono poniżej:

- **Heurystyki strukturalne:** inspirowane rodziną miar predykcji krawędzi w grafach (Common Neighbors, Jaccard, Adamic-Adar, Preferential Attachment) [38, 41]. Ponieważ graf przepływu danych jest dwudzielny, miary oparte na wspólnych sąsiadach są w nim nieskuteczne. Zaadaptowano je więc do postaci scoringu pojedynczego węzła opartego na stopniu i roli w DAG.
- **Random Forest:** implementacja z biblioteki `scikit-learn` [48]. Adaptacja: wejściem jest autorski wektor cech topologicznych węzła (tab. 3.3) zamiast cech pary obiektów, a niezbalansowanie klas obsłużono przez `class_weight`.
- **RUSBoost:** implementacja z biblioteki `imbalanced-learn` [37], wybrana dla bezpośredniego nawiązania do pracy Boińskiego et al. [6]. Adaptacja: klasyfikacja węzła zamiast pary, na cechach topologicznych.
- **LightGBM:** biblioteka gradientowego boostingu firmy Microsoft [31]. Adaptacja: klasyfikacja węzła na cechach topologicznych, z kompensacją rozkładu klas przez `class_weight`. Hiperparametrów nie strojono, a wszystkie klasyfikatory porównywane są w konfiguracjach domyślnych (por. sekcja 4.11).
- **LineageDetector**, wkład własny: łączy powyższe cechy z autorskim relacyjnym score'em kompletności peer-consistency (sekcja 3.5.3) i kalibracją izotoniczną. Nie ma bezpośredniego odpowiednika w literaturze.
- **Adapter grafu DUT**, wkład własny: przekształca benchmark Dutkiewicza et al. [18] z wierszowej reprezentacji lineage do modelu tabela-zadanie-*DATA_FLOW* (sekcja 3.2.2). Sam benchmark wraz ze scenariuszami pochodzi z pracy źródłowej.

Rozgraniczenie komponentów zapożyczonych, z jawnie wskazanym źródłem, od elementów autorskich pozwala jednoznacznie ocenić rzeczywisty wkład pracy i odróżnić go od narzędzi ogólnego przeznaczenia. Ma ono również znaczenie dla interpretacji wyników rozdziału 4. Klasyfikatory bazowe i LineageDetector korzystają z tego samego wektora cech topologicznych, tych samych implementacji bibliotecznych i tego samego potoku ewaluacji. Detektor różni się od klasyfikatora Random Forest, na którym jest oparty, przede wszystkim elementami autorskimi, czyli score'em kompletności i kalibracją. Wpływ każdego z tych elementów na wynik zmierzono bezpośrednio w badaniu ablacyjnym (sekcja 4.5), co pozwala oddzielić wkład własny od skuteczności samych metod bibliotecznych.

Rozdział 4

Ocena rozwiązania

W rozdziale przedstawiono wyniki eksperymentów przeprowadzonych zgodnie z metodyką opisaną w rozdziale 3. Dla każdej z metod detekcji podano wartości metryk rankingowych uśrednione po grafach zbioru DLG-DG-23 w protokole indukcyjnym. Rozdział otwiera badanie wstępne dotyczące predykcji krawędzi, którego wyniki uzasadniają ujęcie węzłowe. Kolejne sekcje przedstawiają wyniki główne, ich istotność statystyczną, badanie ablacyjne detektora, analizę wrażliwości i ważności cech, warianty protokołu ewaluacji oraz test na zewnętrznym grafie DUT. Rozdział zamykają interpretacja wyników i omówienie zagrożeń trafności.

4.1 Badanie wstępne – predykcja krawędzi

Punktem wyjścia pracy było ujęcie broken lineage jako *predykcji brakujących krawędzi*, zgodne z dotychczasową literaturą. W badaniu wstępnym każdy z 18 grafów poddano trzem scenariuszom usuwania krawędzi (oznaczonym A, B, C, różniącym się sposobem doboru krawędzi usuwanych i próbkowaniem negatywów), a następnie oceniono zdolność metod do odtworzenia usuniętych powiązań. Testowano heurystyki predykcji krawędzi wywodzące się z analizy sieci złożonych [38, 41] (Preferential Attachment [5], L3 [34], Katz [30] oraz Personalized PageRank [46]), klasyczne klasyfikatory (Random Forest, RUSBoost, LightGBM) oraz zanurzenia sieciowe (Node2Vec [22] + MLP), wszystkie w tym samym protokole indukcyjnym cross-graph.

Wyniki okazały się niesatysfakcjonujące i niestabilne. Na grafach wiarygodnych (dostatecznie liczna klasa pozytywna w zbiorze testowym) średnie AUC-ROC utrzymywało się w pobliżu poziomu losowego (0,5), przy bardzo wysokiej wariancji między grafami i scenariuszami. Jedynie pojedyncze pary (graf, scenariusz) osiągały AUC-ROC rzędu 0,70, lecz bez powtarzalności, a żadna metoda nie generalizowała się w sposób spójny na grafy niewidziane. Obserwacja ta jest zbieżna z wynikami Dutkiewicza et al. [18], u których scenariusz tabel tymczasowych, najczęstsza praktyczna przyczyna broken lineage, osiągał AUC-ROC 0,49, czyli poziom losowy, nawet dla zaawansowanych metod grafowo-semantycznych.

Przyczyną jest rzadkość grafów DLG-DG-23, w których liczba krawędzi przepływu danych jest o rząd wielkości mniejsza od liczby węzłów (tab. 3.1). Z tego powodu sygnał o konkretnej brakującej parze obiektów jest zbyt słaby, aby umożliwić wiarygodną predykcję krawędzi bez dostępu do semantyki nazw. Wynik ten bezpośrednio motywuje zmianę ujęcia problemu na poziom węzłów (sekcja 2.5). Zamiast pytać, która krawędź została utracona, pyta się, które tabele są dotknięte brakiem. Tak postawione zadanie w mniejszym stopniu zależy od pojedynczej krawędzi, a przez to pozostaje wykonalne mimo rzadkości grafu.

4.2 Wyniki detekcji węzłów o zerwanym lineage

Tabela 4.1 przedstawia średnie metryki rankingowe wszystkich metod detekcji w protokole indukcyjnym, w wariancie uczciwym (z wykluczeniem węzłów izolowanych, sekcja 3.3.2), uśrednione po ośmiu grafach wiarygodnych. Wariant ten przyjęto jako główny, ponieważ nie korzysta z trywialnego przecieku „tabela izolowana $\Rightarrow$ zainfekowana” (por. sekcja 4.6).

TABELA 4.1: Średnie metryki detekcji zainfekowanych tabel per metoda (protokół indukcyjny, wariant uczciwy), wraz z odchyleniem standardowym po ośmiu grafach wiarygodnych. Gwiazdką oznaczono wkład własny, a najlepszą wartość w kolumnie pogrubiono.


Metoda	AUC-ROC	AUC-PR	P@k	Brier
<i>Heurystyki strukturalne</i>				
Anomalia stopnia	0,427 $\pm$ 0,045	0,165 $\pm$ 0,052	0,142 $\pm$ 0,070	0,134 $\pm$ 0,026
Brzeg (root/leaf)	0,455 $\pm$ 0,046	0,137 $\pm$ 0,028	0,146 $\pm$ 0,038	0,745 $\pm$ 0,088
Niska łączność zadań	0,324 $\pm$ 0,069	0,112 $\pm$ 0,026	0,094 $\pm$ 0,055	0,226 $\pm$ 0,016
Reguła korzenia	0,574 $\pm$ 0,062	0,168 $\pm$ 0,025	0,180 $\pm$ 0,120	0,469 $\pm$ 0,071
<i>Klasyczne metody uczenia maszynowego</i>				
Random Forest	0,749 $\pm$ 0,064	0,425 $\pm$ 0,085	0,380 $\pm$ 0,131	0,117 $\pm$ 0,024
RUSBoost	0,631 $\pm$ 0,040	0,249 $\pm$ 0,036	0,340 $\pm$ 0,061	0,152 $\pm$ 0,048
LightGBM	0,720 $\pm$ 0,077	0,381 $\pm$ 0,065	0,398 $\pm$ 0,059	0,147 $\pm$ 0,022
<i>Autorski detektor</i>				
LineageDetector*	0,771 $\pm$ 0,056	0,435 $\pm$ 0,049	0,443 $\pm$ 0,068	0,106 $\pm$ 0,020

W przyjętym biegu k równa się liczbie tabel faktycznie zainfekowanych w grafie testowym, przez co Precision@k, Recall@k i Hits@k przyjmują tę samą wartość. W tabeli podano zatem jedną kolumnę (P@k), a relację tę opisano słownie, aby nie sugerować trzech niezależnych metryk.

LineageDetector uzyskał najwyższą wartość średnią na wszystkich czterech metrykach jednocześnie. Skala tej przewagi zależy jednak silnie od punktu odniesienia. Nad LightGBM wynosi +0,051 AUC-ROC i +0,054 AUC-PR, nad Random Forest już tylko +0,022 i +0,010, czyli mniej niż połowę odchylenia standardowego obu metod. Sama różnica średnich nie wystarcza zatem do orzeczenia o przewadze. Jej istotność statystyczną zbadano w sekcji 4.4, a udział poszczególnych składników detektora w tym wyniku w badaniu ablacyjnym w sekcji 4.5.

Heurystyki strukturalne oparte na lokalnym symptomie wypadają słabo. Żadna nie przekracza AUC-ROC 0,58, a trzy z czterech plasują się poniżej poziomu losowego. Wynika to z natury zadania w wariancie uczciwym, ponieważ po wykluczeniu tabel w pełni izolowanych symptom lokalny (niski stopień, pozycja na brzegu) przestaje wystarczać, ponieważ osierocona tabela-następnik jest strukturalnie nieodróżnialna od prawdziwej tabeli źródłowej (sekcja 3.1). Rozróżnienie tych przypadków wymaga sygnału relacyjnego oraz uczenia indukcyjnego, a te pojawiają się dopiero w klasycznych klasyfikatorach i w LineageDetectorze. Rysunek 4.1 zestawia AUC-ROC wszystkich metod w wariancie uczciwym i zawyżonym, a różnicę między wariantami omówiono w sekcji 4.6.

Relacyjny score kompletności, na którym opiera się wkład LineageDetector, użyty samodzielnie jako heurystyka osiąga AUC-ROC 0,559, AUC-PR 0,206 i P@k 0,240, a więc wyraźnie powyżej pozostałych heurystyk lokalnych po stronie AUC-PR i P@k. Informacja relacyjna, czyli spójność tabeli z jej peerami, okazuje się zatem bogatsza od samego stopnia węzła. Jej pełną wartość wydobywa jednak dopiero LineageDetector, który łączy ją z cechami pozycji w DAG i kalibracją.



RYSUNEK 4.1: Porównanie AUC-ROC metod detekcji w wariancie uczciwym (z wykluczeniem węzłów izolowanych) i zawyżonym. Dla każdej metody dolny, kolorowy słupek przedstawia wariant uczciwy, a górny, jasnoszary słupek wariant zawyżony. Kolor słupka wariantu uczciwego oznacza grupę metod (pomarańczowy – autorski detektor, niebieski – klasyczne metody uczenia maszynowego, szary – heurystyki strukturalne). Poziome odcinki na końcach słupków pokazują odchylenie standardowe po grafach wiarygodnych, a pionowa linia kropkowana poziom losowy (AUC-ROC = 0,5). Gwiazdką oznaczono wkład własny. Metody uczone zachowują przewagę obu wariantach, a heurystyki lokalne tracą najwięcej po usunięciu przecieku izolacji.

4.3 Wyniki w rozbiściu na poszczególne grafy

Średnie z tabeli 4.1 ukrywają rozrzut między grafami, który w tym zadaniu jest znaczny i który stanowi zarazem podstawę sparowanego testu z sekcji 4.4. Tabela 4.2 przedstawia AUC-ROC osobno dla każdego z ośmiu grafów wiarygodnych, wraz z liczbą kandydatów i liczbą tabel zainfekowanych. Wyniki dla wszystkich 18 grafów i wszystkich czterech metryk, łącznie z grafami odrzuconymi progiem wiarygodności, zawiera dodatek B.

TABELA 4.2: AUC-ROC w rozbiściu na grafy testowe (protokół indukcyjny, wariant uczciwy). Kand. oznacza liczbę tabel-kandydatów, Zainf. liczbę tabel zainfekowanych. Najlepszą wartość w wierszu pogrubiono.

Graf	Kand.	Zainf.	Reguła korzenia	Score kompl.	Random Forest	RUS-Boost	Light-GBM	Lineage-Detector*
DLG5	66	9	0,590	0,567	0,662	0,703	0,633	0,745
DLG6	568	82	0,567	0,627	0,745	0,619	0,707	0,790
DLG10	213	36	0,544	0,428	0,681	0,586	0,588	0,714
DLG11	65	6	0,642	0,492	0,732	0,658	0,776	0,804
DLG12	197	26	0,457	0,585	0,855	0,604	0,837	0,869
DLG13	100	13	0,678	0,602	0,723	0,674	0,697	0,692
DLG16	246	44	0,565	0,626	0,841	0,599	0,783	0,818
DLG18	625	110	0,549	0,547	0,750	0,601	0,737	0,733
<i>średnia</i>			0,574	0,559	0,749	0,631	0,720	0,771

Rozbicie na poszczególne grafy pokazuje trzy prawidłowości, które w samych średnich pozostają niewidoczne. Przede wszystkim rozrzut między grafami jest duży w stosunku do różnic między metodami. Wynik LineageDetectora waha się od 0,692 (DLG13) do 0,869 (DLG12), a ta rozpiętość 0,18 jest ośmiokrotnie większa od jego przewagi nad Random Forest w średniej (0,022). Zmienność między grafami dominuje więc nad zmiennością między metodami uczonymi, co bezpośrednio tłumaczy brak istotności statystycznej stwierdzony w sekcji 4.4.

Przewaga detektora nie jest przy tym jednorodna. LineageDetector wypada najlepiej na pięciu z ośmiu grafów, a na pozostałych trzech (DLG13, DLG16, DLG18) ustępuje Random Forest, za każdym razem niewiele, o 0,017–0,031. Nie widać tu systematycznej zależności od rozmiaru grafu, ponieważ detektor wygrywa zarówno na najmniejszym (DLG11, 65 kandydatów), jak i na jednym z największych (DLG6, 568), a przegrywa na grafie średnim (DLG13, 100) i największym (DLG18, 625).

Stabilne pozostaje natomiast uporządkowanie całych klas metod. Na każdym z ośmiu grafów obie najlepsze metody uczone (Random Forest i LineageDetector) przewyższają obie przedstawione heurystyki, a różnica wynosi od 0,014 (DLG13) do 0,270 (DLG12), przy medianie około 0,13. Wniosek o przewadze uczenia indukcyjnego nad regułami lokalnymi nie zależy więc od doboru grafu testowego, inaczej niż porównania wewnątrz grupy metod uczonych.

Udział tabel zainfekowanych wśród kandydatów wynosi średnio 14,5% i jest zbliżony we wszystkich grafach (od 9% dla DLG11 do 18% dla DLG16). Zadanie jest zatem porównywalnie nieźrównoważone niezależnie od skali grafu.

4.4 Istotność statystyczna różnic

Różnice średnich z tabeli 4.1 są w części przypadków mniejsze od odchyłeń standardowych, dlatego zbadano ich istotność statystyczną. Zastosowano test kolejności par Wilcozona [58] (*signed-rank*) w wariancie dokładnym i dwustronnym, sparowany po grafach testowych, zgodnie z zaleceniem Demšara [16] dla porównywania klasyfikatorów na wielu zbiorach danych. Jednostką obserwacji jest graf wiarygodny, a nie pojedynczy węzeł, ponieważ pary są zależne (ten sam graf, ten sam podział indukcyjny), co wyklucza testy zakładające niezależność obserwacji.

Poprawkę Holma [27] na wielokrotne porównania zastosowano *w obrębie rodziny hipotez*, wyróżniając dwie rodziny odpowiadające dwóm pytaniom pracy: porównanie z heurystykami (5 testów) oraz porównanie z klasycznymi klasyfikatorami (3 testy). Podział ten jest podyktowany mocą testu. Przy ośmiu parach najniższe osiągalne p wynosi $2/2^8 = 0,0078$, więc korekta na wszystkich ośmiu porównaniach naraz podniosłaby próg do 0,0625. Przy takim planie żadna różnica nie mogłaby zostać uznana za istotną, niezależnie od danych. Wyniki zestawia tabela 4.3.

Z testów płyną trzy wnioski. Pierwszy dotyczy przewagi nad heurystykami, która jest wyraźna i konsekwentna. We wszystkich dwudziestu porównaniach ($5 \text{ heurystyk} \times 4 \text{ metryki}$) LineageDetector wypada lepiej przy $p_{\text{Holm}} = 0,039$ i wygrywa na ośmiu z ośmiu grafów, a w przypadku reguły korzenia i score'u kompletności w części metryk na siedmiu z ośmiu. Mediany różnic są przy tym duże, od +0,18 do +0,47 AUC-ROC. Wniosek, że uczenie indukcyjne na cechach topologicznych przewyższa reguły oparte na lokalnym symptomie, ma zatem oparcie statystyczne, a nie tylko w różnicy średnich.

Drugi wniosek dotyczy metod boostingowych, wobec których przewaga jest istotna, choć umiarkowana. Nad RUSBoostem LineageDetector wygrywa istotnie w AUC-ROC, AUC-PR i Brier ($p_{\text{Holm}} = 0,023$, 8/8 grafów), a nad LightGBM w AUC-PR i Brier (również $p_{\text{Holm}} = 0,023$, 8/8). Są to metryki najbardziej wrażliwe na nieźrównoważenie klas i na jakość oszacowań prawdopodobieństwa, a więc te, które w zadaniu rankingowym mają największe znaczenie praktyczne.

TABELA 4.3: Istotność statystyczna różnic między LineageDetectorem a pozostałymi metodami. Test kolejności par Wilcoxona (dokładny, dwustronny), sparowany po 8 grafach wiarygodnych, z poprawką Holma w obrębie rodziny hipotez i metryki. Δ oznacza medianę różnicy na korzyść LineageDetector.

Porównanie z	AUC-ROC		AUC-PR		P@k		Brier	
	Δ	p	Δ	p	Δ	p	Δ	p
<i>Heurystyki</i>								
Anomalia stopnia	+0,344	0,039*	+0,273	0,039*	+0,297	0,039*	+0,029	0,039*
Brzeg (root/leaf)	+0,315	0,039*	+0,279	0,039*	+0,297	0,039*	+0,633	0,039*
Niska łączność zadań	+0,466	0,039*	+0,310	0,039*	+0,352	0,039*	+0,119	0,039*
Reguła korzenia	+0,177	0,039*	+0,253	0,039*	+0,250	0,039*	+0,344	0,039*
Score kompletności	+0,189	0,039*	+0,223	0,039*	+0,193	0,039*	+0,040	0,039*
<i>Metody uczone</i>								
Random Forest	+0,023	0,250	+0,014	0,461	+0,064	0,188	+0,012	0,109
RUSBoost	+0,139	0,023*	+0,172	0,023*	+0,071	0,188	+0,041	0,023*
LightGBM	+0,033	0,078	+0,047	0,023*	+0,054	0,188	+0,042	0,023*

* różnica istotna na poziomie $\alpha = 0,05$ po poprawce Holma. Różnica dodatnia oznacza przewagę LineageDetector (dla Brier score wartość niższą). Przy 8 parach najniższe osiągalne p wynosi 0,0078, co ogranicza moc testu.

Trzeci wniosek jest negatywny, ponieważ wobec Random Forest przewagi wykazać się nie udało. Na żadnej z czterech metryk różnica nie osiąga istotności ($p_{\text{Holm}} = 0,109\text{--}0,461$), a liczba wygranych grafów (5–6 na 8) jest bliska losowej. W świetle zebranych danych LineageDetector i Random Forest należy uznać za statystycznie nierozróżnialne pod względem jakości rankingu, a przewagę 0,771 wobec 0,749 AUC-ROC za mieszczącą się w granicach szumu. Nie oznacza to równoważności obu metod. Przy ośmiu parach test wykrywa jedynie efekty duże, więc brak istotności jest równie dobrze zgodny z istnieniem różnicy małej, której przy tej liczbie grafów wykryć się nie da. Rozstrzygnięcie wymagałoby zbioru o większej liczbie grafów.

4.5 Badanie ablacyjne detektora

Detektor LineageDetector łączy dwa autorskie składniki nadbudowane nad klasyfikatorem bazowym: relacyjny score kompletności peer-consistency oraz kalibrację izotoniczną. Aby rozdzielić ich udział w wyniku, przeprowadzono badanie ablacyjne w pełnym planie 2×2 , w którym każdy ze składników wyłączano osobno i obydwie naraz (parametry `use_completeness` i `calibrate`). Konfiguracja pozostała identyczna z biegiem kanonicznym, dzięki czemu wiersz „pełny detektor” odtwarza dokładnie wartości z tabeli 4.1. Wyniki przedstawia tabela 4.4.

TABELA 4.4: Badanie ablacyjne LineageDetector (protokół indukcyjny, wariant uczciwy, 8 grafów wiarygodnych). W nawiasach podano różnicę względem pełnego detektora, przy czym znak dla Brier score odwrócono tak, aby wartość ujemna zawsze oznaczała pogorszenie.

Wariant	AUC-ROC	AUC-PR	P@k	Brier
Pełny detektor	0,771	0,435	0,443	0,106
bez kalibracji izotonicznej	0,786 (+0,015)	0,440 (+0,005)	0,446 (+0,003)	0,111 (−0,005)
bez score’u kompletności	0,747 (−0,023)	0,420 (−0,015)	0,401 (−0,042)*	0,107 (−0,001)
bez obu składników	0,750 (−0,020)	0,425 (−0,010)	0,387 (−0,056)	0,116 (−0,010)

* ubytek istotny statystycznie (test Wilcoxona sparowany po grafach, poprawka Holma w obrębie metryki, $p_{\text{Holm}} = 0,023$, pogorszenie na 8 z 8 grafów). Pozostałe różnice nie osiągają istotności.

Za wkład detektora odpowiada score kompletności. Jego wyłączenie pogarsza wszystkie cztery metryki, a w przypadku Precision@k, najbardziej praktycznej z nich, bo opisującej trafność czołówki rankingu przekazywanej do ręcznej inspekcji, ubytek $-0,042$ jest istotny statystycznie i konsekwentny, ponieważ wariant bez kompletności przegrywa na wszystkich ośmiu grafach. Bez tego składnika detektor spada do poziomu Random Forest (0,747 wobec 0,749 AUC-ROC), co zgadza się z jego konstrukcją, bazowym estymatorem jest bowiem właśnie Random Forest. Po usunięciu cech relacyjnych oba modele stają się niemal tożsame. To sygnał peer-consistency odróżnia zatem autorski detektor od gotowego klasyfikatora.

Kalibracja izotoniczna nie poprawia rankingu, lecz go pogarsza. Wynik ten przeczy oczekiwaniom i wymaga jasnego zaraportowania. Wariant bez kalibracji osiąga wyższe AUC-ROC (0,786 wobec 0,771) oraz nieznacznie wyższe AUC-PR i Precision@k, wygrywając odpowiednio na 7 i 5 z 8 grafów. Poprawia natomiast to, do czego służy, czyli Brier score (0,106 wobec 0,111, poprawa na 6 z 8 grafów), choć i ta różnica nie osiąga istotności statystycznej. Mechanizm tego zjawiska jest znany. Regresja izotoniczna jest funkcją schodkową [61, 44], więc przypisuje identyczne prawdopodobieństwo całym grupom węzłów i wprowadza do rankingu remisy, których surowy klasyfikator nie miał. Dodatkowo w schemacie `CalibratedClassifierCV` z $cv = 3$ każdy model składowy uczy się na dwóch trzecich puli treningowej. Kalibracja oznacza więc kompromis, w którym część zdolności rozdzielczej modelu zostaje oddana w zamian za rzetelność oszacowań prawdopodobieństwa.

Dla konstrukcji detektora płynie stąd praktyczny wniosek. Kalibrację warto zachować tylko wtedy, gdy odbiorcą wyniku ma być wartość p (zainfekowana) interpretowana jako prawdopodobieństwo, na przykład przy progowaniu ryzyka albo szacowaniu kosztu inspekcji. Jeśli celem jest wyłącznie uszeregowanie tabel do przeglądu, lepiej wybrać wariant bez kalibracji. W pracy jako konfigurację główną zachowano wariant skalibrowany, ponieważ zadanie zdefiniowano (sekcja 3.1) jako oszacowanie prawdopodobieństwa, a nie sam ranking. Alternatywa jest udokumentowana powyżej i pozostaje dostępną jako parametr implementacji.

4.6 Kontrola przecieku i analiza wrażliwości

4.6.1 Przeciek izolacji

Usunięcie zadania może pozbawić tabelę wszystkich krawędzi przepływu danych, czyniąc ją w pełni izolowaną w podgrafie `DATA_FLOW`. Ponieważ w oryginalnych grafach tabele izolowane nie występują, trywialna reguła „tabela izolowana $\Rightarrow$ zainfekowana” pozwala rozpoznać znaczną część pozytywów bez żadnego uczenia i sztucznie zawyża wynik. Aby zmierzyć skalę tego zjawiska, każdą metodę oceniono w dwóch wariantach: *zawyżonym* (izolowane pozostają w puli kandydatów) oraz *uczciwym* (flaga `exclude_isolated` usuwa je z puli). Tabela 4.5 zestawia oba warianty, a rysunek 4.1 przedstawia je graficznie.

TABELA 4.5: Wpływ przecieku izolacji na AUC-ROC (protokół indukcyjny).

Metoda	Zawyżony	Uczciwy
Brzeg (root/leaf)	0,600	0,455
Niska łączność zadań	0,518	0,324
Random Forest	0,816	0,749
LightGBM	0,805	0,720
LineageDetector *	0,842	0,771

Heurystyki lokalne tracą najwięcej. Wynik heurystyki `boundary` spada z 0,600 do 0,455, a `low_job_connectivity` z 0,518 do 0,324, co oznacza, że obie opierały się głównie na przecieku izolacji.

Metody uczone tracą znacznie mniej (Random Forest z 0,816 do 0,749, LineageDetector z 0,842 do 0,771), co pokazuje, że opierają się na rzeczywistym sygnale strukturalnym, a nie na trywialnej regule. W obu wariantach LineageDetector pozostaje najlepszy.

Oba warianty uśredniono po różnej liczbie grafów wiarygodnych, ośmiu w wariantie uczciwym i dziesięciu w zawyżonym. Wykluczenie izolowanych zmniejsza liczbę pozytywów, przez co dwa grafy spadają poniżej progu $\text{MIN_POS} = 5$. Z tego powodu wartości w tabeli 4.5 ilustrują tendencję (metody uczone są odporniejsze na usunięcie przecieku), a nie dokładny ubytek, dlatego ich kolumn nie należy odejmować 1:1.


4.6.2 Wrażliwość na odsetek usuwanych zadań

Zbadano wpływ parametru `removal_ratio` (udział usuwanych zadań łączących) na wynik LineageDetector, przy wartościach 0,05, 0,10, 0,20 i 0,30 (tabela 4.6).

TABELA 4.6: Wrażliwość LineageDetector na `removal_ratio` (AUC-ROC, protokół indukcyjny).

<code>removal_ratio</code>	0,05	0,10	0,20	0,30
AUC-ROC	0,761	0,771	0,755	0,754

Wynik jest stabilny, ponieważ w całym badanym zakresie AUC-ROC mieści się w przedziale 0,754–0,771, a różnice są rzędu wariancji między powtórzeniami. Skuteczność detektora nie zależy zatem istotnie od intensywności symulowanego broken lineage. Zarówno przy rzadkich (5%), jak i częstych (30%) usunięciach zadań detektor zachowuje porównywalną jakość rankingu (rys. 4.2).



* wkład własny. Wynik LineageDetectora niemal stały (0,754–0,771), nie jest artefaktem wyboru `removal_ratio`.

RYСУNEK 4.2: Wrażliwość AUC-ROC detektora LineageDetector na parametr `removal_ratio`. Wynik pozostaje stabilny w całym badanym zakresie.

4.7 Ważność cech

Badanie ablacyjne pokazało, że score kompletności wnosi informację, natomiast analiza ważności cech odpowiada na pytanie, które elementy opisu węzła niosą sygnał. Zastosowano metodę permutacyjną [7], w której wartości pojedynczej cechy przestawia się losowo w zbiorze testowym, a spadek

AUC-ROC mierzy, ile model tracił bez tej informacji. W odróżnieniu od ważności wbudowanej w drzewa decyzyjne (opartej na spadku nieczystości węzłów) metoda ta nie faworyzuje cech o wielu unikatowych wartościach [56] i mierzy wpływ na metrykę, która faktycznie podlega ocenie. Wyniki uśredniono po 10 permutacjach, ośmiu grafach wiarygodnych i trzech ziarnach (tabela 4.7).

TABELA 4.7: Ważność cech detektora LineageDetector mierzona metodą permutacyjną: średni spadek AUC-ROC po losowym przestawieniu wartości cechy. Gwiazdką oznaczono cechy wnoszone przez autorski score kompletności.

Cecha	Spadek AUC-ROC	Odch. std
avg_job_in_df – śr. stopień wej. zadań	+0,0616	0,0510
n_job_neighbors – liczba sąsiednich zadań	+0,0492	0,0266
out_df – wyjściowe krawędzie <i>DATA_FLOW</i>	+0,0408	0,0207
degree – stopień całkowity	+0,0260	0,0336
peer_producer_score*	+0,0238	0,0240
n_field_children – liczba pól tabeli	+0,0196	0,0280
role – rola w przepływie	+0,0128	0,0204
completeness_anomaly*	+0,0107	0,0140
is_root – brak producenta	+0,0100	0,0110
flow_depth – głębokość w DAG	+0,0072	0,0130
in_df – wejściowe krawędzie <i>DATA_FLOW</i>	+0,0065	0,0125
is_leaf – brak konsumenta	+0,0036	0,0128
depth_plus_reach – długość ścieżki	+0,0018	0,0292
peer_consumer_score*	0,0000	0,0000
avg_job_out_df – śr. stopień wyj. zadań	−0,0008	0,0046
flow_reach – zasięg w dół DAG	−0,0015	0,0276

Najsilniejszy sygnał pochodzi z otoczenia węzła, a nie z niego samego. Dwie najważniejsze cechy, średni stopień wejściowy sąsiednich zadań oraz liczba sąsiadujących zadań, opisują nie tabelę, lecz jej kontekst. Wyprzedzają one cechy opisujące bezpośrednio symptom zerwania (*in_df*, *is_root*), które plasują się w dolnej połowie zestawienia. Potwierdza to diagnozę z sekcji 4.10, zgodnie z którą sam brak producenta nie odróżnia tabeli osieroconej od prawdziwego źródła, a informacja rozstrzygająca leży w sąsiedztwie węzła.

Wkład autorskiego score’u jest widoczny, lecz jednostronny. Cecha *peer_producer_score* zajmuje piąte miejsce na szesnastce i jest najwyżej sklasyfikowaną cechą relacyjną, a *completeness_anomaly* plasuje się ósma. Uwagę zwraca natomiast cecha *peer_consumer_score*, której przedstawienie w ogóle nie zmienia wyniku. Spadek wynosi dokładnie zero przy zerowym odchyleniu standardowym we wszystkich 24 kombinacjach grafu i ziarna.

Przyczyna jest strukturalna, a nie implementacyjna. W zbiorze DLG-DG-23 każde zadanie zapisuje dokładnie jedną tabelę wyjściową, co sprawdzono na wszystkich zadaniach we wszystkich grafach. Zbiór peerów po stronie konsumenta $C(t)$, zdefiniowany jako inne tabele zapisywane przez te same zadania upstream, jest zatem zawsze pusty, a wynikający z niego score równy tożsamościowo zeru. Wynikają stąd dwie konsekwencje. Definicja sygnału anomalii z sekcji 3.5.3 redukuje się na tym zbiorze do członu producenta, czyli $\text{anomaly}(t) = \mathbf{1}[\text{in_df}(t) = 0] \cdot \text{prod}(t)$. Detektor korzysta zaś w praktyce z 15, a nie 16 cech.

Nie jest to błąd konstrukcji. Sformułowanie score’u pozostaje symetryczne i na zbiorze dopuszczającym zadania o wielu wyjściach (np. operacje partycjonowania lub rozgałęzienia potoku) strona konsumenta byłaby aktywna. Obserwacja ta ma jednak dwie praktyczne implikacje. Potencjał score’u peer-consistency jest na zbiorze DLG-DG-23 wykorzystany tylko w połowie, co może częściowo tłumaczyć umiarkowaną skalę przewagi detektora (sekcja 4.4). Wzmacnia to również wyjaśnienie porażki sygnału relacyjnego na zewnętrznym grafie DUT (sekcja 4.9), na którym nieaktywna jest także strona producenta, przez co score przyjmuje stale wartość zerową.

4.8 Warianty protokołu ewaluacji

Wyniki główne uzyskano w jednym, ściśle określonym protokole, czyli indukcyjnym leave-one-graph-out, z losowym usuwaniem 10% zadań łączących. Powstaje pytanie, na ile wnioski zależą od tego wyboru. Zbadano zatem trzy warianty kontrolne, z których każdy zmienia jeden element protokołu przy zachowaniu pozostałych ustawień biegu kanonicznego. Tabela 4.8 zestawia wyniki. Dla porównywalności wszystkie warianty ograniczono do tych samych pięciu dużych grafów, na których każdy z nich daje wiarygodne metryki.

TABELA 4.8: Wpływ zmiany protokołu ewaluacji na AUC-ROC. Wszystkie warianty na tych samych pięciu grafach testowych (DLG6, DLG10, DLG12, DLG16, DLG18), `removal_ratio = 0,10`, wariant uczciwy.

Metoda	Indukcyjny (kanoniczny)	Transduktywny	Skala: małe→duże
Anomalia stopnia	0,410	0,392	0,410
Brzeg (root/leaf)	0,480	0,482	0,480
Niska łączność zadań	0,355	0,373	0,355
Random Forest	0,774	0,819	0,626
RUSBoost	0,602	0,634	0,613
LightGBM	0,731	0,769	0,638
LineageDetector*	0,785	0,804	0,623

4.8.1 Protokół transduktywny

W wariantcie transduktywnym podział na zbiór treningowy i testowy przebiega wewnątrz grafu (60/40 węzłów), a nie między grafami. Model widzi zatem w treningu fragment tej samej struktury, na której jest oceniany. Wszystkie metody uczone zyskują, co potwierdza, że protokół indukcyjny przyjęty jako główny jest istotnie trudniejszy, a więc i uczciwszy.

Rozkład tego zysku jest jednak nierówny i sam w sobie stanowi wynik. Random Forest zyskuje najwięcej (o 0,045, z 0,774 do 0,819), LineageDetector wyraźnie mniej (o 0,019, z 0,785 do 0,804). Przewaga Random Forest ujawnia się zatem dopiero wtedy, gdy model może dopasować się do konkretnego grafu. Sygnał relacyjny wykorzystywany przez LineageDetector przenosi się między grafami lepiej, co zgadza się z jego konstrukcją, ponieważ porównanie tabeli z jej peerami pozostaje z natury niezależne od globalnych właściwości grafu. W protokole transduktywnym Random Forest wysuwa się na prowadzenie, w indukcyjnym obie metody są nierozróżnialne (sekcja 4.4).

4.8.2 Generalizacja na większą skalę

Wariant trzeci sprawdza najtrudniejszy przypadek praktyczny, w którym model uczony na 10 małych i 3 średnich grafach ocenia grafy duże, o rząd wielkości liczniejszy w węzły. Skuteczność wszystkich metod uczonych spada drastycznie, z okolic 0,73–0,79 do 0,61–0,64 AUC-ROC, czyli o około 0,15. Heurystyki nie korzystają z treningu, więc pozostają na niezmiennym poziomie.

Jest to najpoważniejsze ograniczenie praktyczne ujawnione w pracy. Wzorce topologiczne wyuczone na małych grafach nie przenoszą się w pełni na grafy duże. W protokole kanonicznym efekt ten nie występuje, ponieważ pula treningowa leave-one-graph-out zawiera zawsze inne grafy duże. Dla zastosowań praktycznych oznacza to, że detektor należy trenować na grafach o skali zbliżonej do docelowej, ponieważ zbiór treningowy złożony wyłącznie z małych instancji nie wystarcza. LineageDetector nie ma w tym wariantcie przewagi (0,623 wobec 0,638 dla LightGBM), ponieważ sygnał peer-consistency, kalibrowany na małych grafach o innej gęstości połączeń, traci trafność.

4.8.3 Pojedyncze zdarzenie broken lineage

Ostatni wariant ma najczystsza interpretację przyczynową. Zamiast usuwać 10% zadań naraz, każdą instancję testową tworzy się przez usunięcie dokładnie jednego zadania (do 30 prób na graf, metryki uśredniane). Jedno zdarzenie broken lineage odpowiada tu jednemu brakującemu zadaniu, a graf pozostaje poza tym nienaruszony. Trening prowadzony jest nadal na puli wielozadaniowej, na grafach niewidzianych. Wyniki zestawia tabela 4.9.

TABELA 4.9: Wariant pojedynczego usuniętego zadania w zestawieniu z biegiem kanonicznym (protokół indukcyjny, wariant uczciwy, 8 grafów wiarygodnych).

Metoda	AUC-ROC		AUC-PR	
	jedno zadanie	kanoniczny	jedno zadanie	kanoniczny
Reguła korzenia	0,518	0,574	0,025	0,168
Score kompletności	0,546	0,559	0,060	0,206
Random Forest	0,792	0,749	0,208	0,425
RUSBoost	0,682	0,631	0,071	0,249
LightGBM	0,767	0,720	0,187	0,382
LineageDetector*	0,799	0,771	0,192	0,435

Wynik rozchodzi się w dwie przeciwne strony i oba kierunki są pouczające. AUC-ROC rośnie, dla LineageDetector z 0,771 do 0,799, a dla Random Forest z 0,749 do 0,792, ponieważ przy jednym usuniętym zadaniu reszta grafu pozostaje spójna, a nieliczne tabele osierocone wyraźniej odcinają się od tła. AUC-PR spada natomiast ponaddwukrotnie (0,435 $\rightarrow$ 0,192 dla detektora), gdyż klasa pozytywna liczy teraz średnio dwie–trzy tabele na 260 kandydatów, czyli poniżej jednego procenta.

Rozbieżność ta ma znaczenie praktyczne i stanowi argument za raportowaniem obu metryk. Wysokie AUC-ROC oznacza, że model niemal zawsze umieszcza tabelę zainfekowaną powyżej losowo wybranej tabeli czystej. Niskie AUC-PR mówi jednak, że w czołówce rankingu przekazywanej do ręcznej inspekcji trafienia i tak będą rzadkie, bo pozytywów jest bardzo mało. Odpowiada to sytuacji praktycznej, w której w dużym grafie produkcyjnym z pojedynczym zerwaniem lineage znalezienie właściwej tabeli pozostaje trudne mimo dobrego uporządkowania rankingu.

Uporządkowanie metod pozostaje bez zmian. LineageDetector osiąga najwyższe AUC-ROC i zdecydowanie najlepszy Brier score (0,042 wobec 0,059 dla Random Forest i 0,117 dla LightGBM), a heurystyki pozostają w pobliżu poziomu losowego. Wniosek jakościowy z biegu kanonicznego jest zatem odporny również na tę zmianę definicji instancji testowej.

4.9 Test na grafie spoza zbioru DLG-DG-23

Dotychczasowe eksperymenty oceniały metody w protokole indukcyjnym wewnątrz jednego zbioru danych. Aby sprawdzić przenośność metody na dane z zupełnie innego źródła, przeprowadzono test cross-dataset. Modele wytrenowano wyłącznie na grafach DLG-DG-23 (małych i średnich, zgodnie ze schematem generalizacji do skali z sekcji 4.8), a następnie oceniono bez douczania na zewnętrznym grafie DUT, opisanym w sekcji 3.2.2. Graf ten zbudowano za pomocą autorskiego adaptera z benchmarku Dutkiewicza et al. [18], obejmującego syntetyczne scenariusze SQL na bazie *Northwind* [43]. Liczy on 21 tabel, 14 zadań i 33 krawędzie przepływu, jest więc o rzędy wielkości mniejszy od grafów DLG-DG-23 i ma inną, łańcuchową topologię. Tabela 4.10 przedstawia wyniki na grafie DUT w wariantcie uczciwym (z wykluczeniem węzłów izolowanych), uśrednione po 20 powtórzeniach.

Najważniejsza obserwacja z tego testu jest taka, że skuteczność metod uczonych nie załamuje się na grafie z innego źródła. Random Forest (0,625), LightGBM (0,674) i LineageDetector (0,641)

osiągają na DUT AUC-ROC porównywalne z ich wynikiem na dużych grafach DLG-DG-23 (odpowiednio 0,617, 0,605, 0,623), mimo że graf testowy pochodzi z zupełnie innej dziedziny i jest znacznie mniejszy. LineageDetector zachowuje przy tym najlepszą kalibrację (Brier 0,187). W wariancie zawyżonym (bez wykluczania izolowanych) przewaga jest jeszcze wyraźniejsza, a LineageDetector osiąga AUC-ROC 0,773 i AUC-PR 0,721. Wzorce topologiczne wyuczone na jednym zbiorze niosą zatem użyteczny sygnał także poza nim.

TABELA 4.10: Wynik na zewnętrznym grafie DUT (trening wyłącznie na DLG-DG-23, wariant uczciwy). W ostatniej kolumnie podano AUC-ROC na dużych grafach DLG-DG-23 jako odniesienie wewnątrz zbioru.

Metoda	Graf zewnętrzny DUT				duże DLG
	AUC-ROC	AUC-PR	P@k	Brier	AUC-ROC
Anomalia stopnia	0,751	0,422	0,436	0,180	0,426
Niska łączność zadań	0,751	0,422	0,436	0,198	0,384
Score kompletności	0,500	0,262	0,189	0,262	0,568
Random Forest	0,625	0,497	0,380	0,225	0,617
RUSBoost	0,489	0,260	0,141	0,216	0,591
LightGBM	0,674	0,564	0,464	0,296	0,605
LineageDetector*	0,641	0,521	0,439	0,187	0,623

Wynik ten obwarowany jest jednak trzema zastrzeżeniami. Po pierwsze, graf DUT jest bardzo mały (21 tabel), więc liczba zainfekowanych tabel spada poniżej progu wiarygodności przyjętego dla DLG-DG-23. Test należy zatem traktować jako jakościowy dowód przenośności (*proof of concept*), a nie precyzyjny benchmark. Po drugie, na tym konkretnym grafie trywialne heurystyki stopnia osiągają wysokie AUC-ROC (0,751), odwrotnie niż wewnątrz DLG-DG-23, gdzie plasują się w okolicy poziomu losowego. Wynika to z łańcuchowej topologii DUT, w której osierocona tabela ma po usunięciu zadania wyraźnie niższy stopień. Na tak prostej strukturze sam stopień staje się więc silnym sygnałem, który jednak nie generalizuje na gęstsze grafy produkcyjne. Po trzecie, relacyjny score kompletności załamuje się na DUT (AUC-ROC 0,500), ponieważ łańcuchowe scenariusze dają każdej tabeli co najwyżej jednego peera, a sygnał peer-consistency wymaga rozgałęzień, których w tym grafie brak. Z tego powodu LineageDetector nie zyskuje na DUT przewagi nad LightGBM, choć pozostaje najlepiej skalibrowany.

Aby sprawdzić, czy powyższe obserwacje nie są artefaktem jednej konfiguracji, powtórzono test w przeglądzie obejmującym dwa warianty izolacji oraz trzy wartości `removal_ratio` (0,2, 0,3 i 0,4), po 25 powtórzeniach na konfigurację. Przegląd potwierdza wszystkie trzy zastrzeżenia i dodaje dwie obserwacje. Jakość metod uczonych rośnie monotonicznie wraz z natężeniem symulowanego zjawiska (w wariancie zawyżonym AUC-ROC LineageDetector wynosi kolejno 0,767, 0,812 i 0,843), co oznacza, że modele reagują na intensywność broken lineage, a nie na szum. Score kompletności osiąga z kolei AUC-ROC równe dokładnie 0,500 we wszystkich sześciu konfiguracjach. Nie jest to więc słaby wynik losowy, lecz sygnał tożsamościowo zerowy, wynikający ze struktury grafu, w którego łańcuchowej topologii tabela nie ma peerów, z którymi mogłaby zostać porównana. Odnotować należy również, że przy najsilniejszym zaburzeniu (`removal_ratio` = 0,4), gdy liczba tabel zainfekowanych zbliża się do progu wiarygodności, LineageDetector wraca na prowadzenie także na DUT (AUC-ROC 0,684 wobec 0,656 dla LightGBM, przy najwyższym P@k 0,555). Przewaga detektora ujawnia się więc dopiero przy dostatecznej liczbie pozytywów, spójnie z obserwacją z sekcji 4.3. Jako liczby główne zachowano wariant `removal_ratio` = 0,3, mieszczący się w zakresie zbadanym w analizie wrażliwości (sekcja 4.6). Pełne zestawienie przeglądu zawiera dodatek C.

Pełne, ilościowe porównanie na drugim zbiorze wymagałoby większego grafu zewnętrznego o topologii rozgałęzionej. Kierunek ten wskazano w rozdziale 5.

4.10 Analiza wyników

Łączna interpretacja wyników z sekcji 4.4 i 4.5 pozwala przypisać skuteczność LineageDetectora poszczególnym źródłom sygnału. Cechy pozycji w grafie DAG opisują węzeł lokalnie i same nie wystarczają do odróżnienia osieroconej tabeli-następnika od prawdziwej tabeli źródłowej. Informację relacyjną wnosi dopiero score kompletności *peer-consistency*, oparty na porównaniu tabeli z peerami zasilającymi te same zadania. Składnik ten odpowiada za przewagę detektora nad klasyfikatorem bazowym. Po jego wyłączeniu wynik detektora spada do poziomu Random Forest, a ubytek precyzji w czołówce rankingu ($P@k$) jest istotny statystycznie.

Rola kalibracji izotonicznej okazała się odmienna od założonej na etapie projektowania detektora. Kalibracja nieznacznie obniża jakość rankingu, poprawiając w zamian rzetelność oszacowań prawdopodobieństwa (Brier score 0,106 wobec 0,111 bez kalibracji). Jej zastosowanie wiąże się zatem z kompromisem między jakością uszeregowania a jakością prawdopodobieństw, którego rozstrzygnięcie zależy od sposobu wykorzystania wyniku detekcji (sekcja 4.5).

Zakres uprawnionych wniosków jest przy tym ograniczony. Przewaga detektora nad heurystykami (we wszystkich metrykach) i nad metodami boostingowymi (w części metryk) została potwierdzona statystycznie, natomiast różnica wobec Random Forest nie osiągnęła istotności. Średnie z tabeli 4.1 nie uzasadniają więc tezy, że autorski detektor jest najlepszą z badanych metod. Wyniki wspierają tezę węższą. Detektor dorównuje najlepszemu klasycznemu klasyfikatorowi i przewyższa metody boostingowe w metrykach najbardziej wrażliwych na niezrównoważenie klas i jakość prawdopodobieństw (AUC-PR i Brier score), a źródłem tej przewagi jest jeden, jednoznacznie wskazany składnik.

Słabe wyniki heurystyk mają dwie przyczyny. Miary oparte na wspólnych sąsiadach, takie jak Common Neighbors, Jaccard czy Adamic-Adar, nie niosą w tym zadaniu informacji, ponieważ podgraf przepływu danych jest *dwudzielny*. Tabele łączą się wyłącznie z zadaniami, więc miary te przyjmują wartość zero dla każdej pary węzłów tego samego typu, co uzasadniało ich wykluczenie z implementacji. Heurystyki oparte na stopniu i roli w grafie mierzą z kolei jedynie lokalny symptom, który po usunięciu przecieku izolacji przestaje wystarczać do skutecznej detekcji.

Główną trudnością zadania pozostaje osierocona tabela-następnik. Po usunięciu zadania traci ona producenta ($in_df = 0$) i staje się strukturalnie identyczna z prawdziwą tabelą źródłową. Rozróżnienie obu przypadków jest możliwe wyłącznie na podstawie kontekstu relacyjnego, czyli informacji o tym, czy peerzy tabeli również są źródłami, oraz uczenia na innych grafach. Wyjaśnia to zarówno przewagę metod indukcyjnych nad heurystykami, jak i istnienie naturalnego pułapu skuteczności sygnału topologicznego ($AUC-ROC \approx 0,77$) przy braku dostępu do semantyki nazw i schematów.

4.11 Zagrożenia trafności

Wnioski z poprzednich sekcji obarczone są ograniczeniami wynikającymi z konstrukcji eksperymentu i z właściwości dostępnych danych. Omówiono je poniżej w czterech kategoriach przyjmowanych w badaniach empirycznych w inżynierii oprogramowania [59]: trafności konstrukcji, wewnętrznej, zewnętrznej oraz wnioskowania statystycznego.

4.11.1 Trafność konstrukcji

Pierwszym zagrożeniem trafności konstrukcji jest posłużenie się etykietą zastępczą w miejsce bezpośredniej obserwacji zjawiska. Za tabelę zainfekowaną uznaje się każdą tabelę incydentną do usuniętego zadania. Jest to definicja operacyjna, która nie stanowi pomiaru rzeczywistego zerwania lineage. W praktyce część takich tabel mogłaby zachować czytelne pochodzenie inną ścieżką (np. przez równoległe zadanie zapisujące te same dane), a inne tabele mogłyby zostać dotknięte zerwaniem nieobjętym symulacją. Uzyskana miara skuteczności odnosi się zatem do zadania zdefiniowanego w pracy, a jej związek z użytecznością detektora dla audytora ma charakter pośredni.

Drugim zagrożeniem jest jednakowe modelowanie różnych przyczyn broken lineage. Tabela tymczasowa, funkcja definiowana przez użytkownika i zapytanie rekurencyjne są reprezentowane w ten sam sposób, jako usunięcie węzła-zadania. Upraszcza to model i uniezależnia go od mechanizmu zjawiska, uniemożliwia jednak sprawdzenie, czy detektor równie skutecznie wykrywa skutki każdej z tych przyczyn.

Trzecie zagrożenie wynika z przyjętej wartości k . W biegu kanonicznym k równa się liczbie tabel faktycznie zainfekowanych, przez co Precision@ k , Recall@ k i Hits@ k przyjmują tę samą wartość. Metryki te nie stanowią więc niezależnych świadectw jakości, a ich zgodność nie jest dodatkowym potwierdzeniem wyniku.

4.11.2 Trafność wewnętrzna

Najważniejszym zagrożeniem trafności wewnętrznej jest przeciek izolacji. Usunięcie zadania może pozostawić tabelę bez żadnej krawędzi przepływu, co pozwala rozpoznać ją trywialną regułą. Zjawisko to zidentyfikowano i zmierzono (19–35% pozytywów, tabela 3.2), a główne wyniki raportowane są w wariancie z wykluczeniem takich tabel. Rozwiązanie to ogranicza problem, ale go nie eliminuje, ponieważ pozostają tabele o częściowo zerwanym lineage, których łatwość wykrycia również zależy od liczby utraconych krawędzi.

Kolejnym zagrożeniem jest losowy dobór usuwanych zadań. W praktyce zerwanie lineage nie jest zdarzeniem losowym i częściej dotyka pewnych klas obiektów, takich jak potoki wsadowe czy procesy tymczasowe. Rozkład symulowanych uszkodzeń może być zatem łatwiejszy albo trudniejszy od rzeczywistego, a kierunek tego obciążenia pozostaje nieznany.

Na wyniki może wpływać również brak strojenia hiperparametrów. Wszystkie klasyfikatory uruchomiono w konfiguracjach domyślnych lub zbliżonych do domyślnych, bez przeszukiwania przestrzeni hiperparametrów. Zapewnia to jednakowe traktowanie metod i eliminuje ryzyko dopasowania konfiguracji do zbioru testowego. Porównanie dotyczy jednak metod w konfiguracji domyślnej i nie odzwierciedla ich maksymalnego potencjału.

4.11.3 Trafność zewnętrzna

Podstawowym ograniczeniem trafności zewnętrznej jest oparcie wyników głównych na jednym zbiorze danych, pochodzącym z jednej domeny. Wszystkie 18 grafów pochodzi od jednego dostawcy chmurowego i nie wiadomo, w jakim stopniu charakterystyczne dla tego środowiska wzorce topologiczne przenoszą się na inne architektury przetwarzania danych. Test na grafie DUT (sekcja 4.9) częściowo uzupełnia tę lukę. Graf ten jest jednak mały (21 tabel) i ma odmienną, łańcuchową topologię, dlatego stanowi dowód jakościowy, a nie ilościowe potwierdzenie przenośności.

Uogólnienie wyników ogranicza także świadome zawężenie sygnału do topologii grafu. Anonimizacja zbioru wymusiła rezygnację z informacji semantycznej, a zarazem ograniczenie to jest przed-

miotem pytania badawczego i zostało przyjęte celowo. Uzyskany pułap skuteczności (AUC-ROC $\approx 0,77$) dotyczy wyłącznie podejścia czysto topologicznego i nie wyznacza granicy dla metod korzystających z nazw obiektów lub metadanych schematu.

4.11.4 Trafność wnioskowania statystycznego

Zasadniczym zagrożeniem trafności wnioskowania statystycznego jest mała liczba jednostek obserwacji. Testy sparowano po ośmiu grafach wiarygodnych, co ogranicza ich moc. Najniższe osiągalne p w dokładnym teście Wilcozona wynosi 0,0078, a efekty małe pozostają niewykrywalne. Brak istotności różnicy wobec Random Forest (sekcja 4.4) należy zatem interpretować jako brak dowodu na różnicę, a nie jako dowód jej braku.

Z tym zagrożeniem wiąże się zależność między powtórzeniami. Trzy powtórzenia biegu kanonicznego różnią się wyłącznie ziarnem losowości doboru usuwanych zadań i operują na tych samych grafach, więc nie zwiększają liczby niezależnych jednostek obserwacji. Uśrednianie po ziarnach (z trymowaniem wartości skrajnych) zmniejsza wariancję oszacowań, lecz nie zwiększa mocy testu.

Ostatnim zagrożeniem jest arbitralny wybór progu wiarygodności $\text{MIN_POS} = 5$. Próg ten decyduje o tym, które grafy wchodzi do agregacji, a przy ośmiu jednostkach obserwacji pojedynczy graf ma zauważalny wpływ na średnią. Z tego powodu obok średnich raportowane są wyniki w rozbiciu na grafy (tabela 4.2).

Rozdział 5

Uwagi końcowe

Niniejsza praca dotyczyła problemu broken lineage, czyli utraty ciągłości grafu zależności między obiektami bazy danych wskutek stosowania tabel tymczasowych, funkcji definiowanych przez użytkownika i innych obiektów pośrednich. Zjawisko to ma bezpośrednie konsekwencje praktyczne, ponieważ niekompletny graf lineage utrudnia audyt danych, kontrolę ich jakości oraz realizację obowiązków wynikających z regulacji takich jak RODO. Istniejące narzędzia zbierają lineage prospektywnie i nie sygnalizują miejsc, w których zebrany graf jest niekompletny, a dotychczasowe prace naukowe ujmują problem wyłącznie jako odtwarzanie brakujących krawędzi.

5.1 Podsumowanie

Celem pracy było zbadanie, w jakim stopniu sama topologia grafu lineage pozwala wskazać tabele o zerwanym pochodzeniu danych. Punktem wyjścia było ujęcie problemu jako predykcji brakujących krawędzi, zgodne z literaturą. Badanie wstępne wykazało jednak, że na rzadkich, zanonimizowanych grafach zbioru DLG-DG-23 skuteczność takiej predykcji nie odbiega od poziomu losowego. Na tej podstawie zadanie przeformułowano na poziom węzłów, jako ranking tabel według prawdopodobieństwa, że ich lineage został zerwany.

Dla tak postawionego zadania opracowano metodykę symulacji broken lineage przez usuwanie zadań, która pozwala automatycznie wyznaczyć etykiety referencyjne, oraz wariant ewaluacji eliminujący trywialny przeciek wynikający z tabel izolowanych. Zaimplementowano i porównano trzy klasy metod detekcji, od heurystyk strukturalnych, przez klasyczne klasyfikatory uczenia maszynowego, po autorski detektor LineageDetector łączący cechy pozycji węzła w grafie z relacyjnym score'em kompletności i kalibracją prawdopodobieństw. Ocenę przeprowadzono w protokole indukcyjnym, uzupełnionym o testy istotności statystycznej, badanie ablacyjne, analizę wrażliwości, warianty protokołu oraz test na zewnętrznym grafie DUT.

Uzyskane wyniki pozwalają odpowiedzieć na cztery pytania badawcze postawione we wstępie. Odpowiedzi te przedstawiono kolejno w dalszej części sekcji, a zamyka ją sformułowanie wniosku głównego.

PB1 – Techniki ekstrakcji grafów lineage. Praca korzysta z gotowych, rzeczywistych grafów zbioru DLG-DG-23, wczytywanych z reprezentacji JSON (węzły + krawędzie z typami `asset_type`, `relation_type`) do postaci skierowanego grafu DAG przepływu danych. Pokazano, że dla zadania detekcji węzłów wystarcza podgraf przepływu (krawędzie `DATA_FLOW` między tabelami a zadaniami), bez potrzeby odtwarzania semantyki nazw czy schematów. Na potrzeby testu przenośności opracowano ponadto adapter, który z benchmarku Dutkiewicza et al. [18], zapisującego lineage na poziomie wierszy w postaci RDF i CSV, wyprowadza gruboziarnisty graf tabela–zadanie zgodny

z DLG-DG-23 (sekcja 3.2.2). Pokazuje to, że reprezentację drobnoziarnistą można sprowadzić do poziomu obiektów przez agregację zależności wierszowych, co pozwala stosować tę samą metodę detekcji do grafów z różnych źródeł.

PB2 – Adaptacja ML do wykrywania niekompletności lineage. Zaadaptowano trzy klasyczne klasyfikatory (Random Forest, RUSBoost, LightGBM) z zadania klasyfikacji par obiektów do klasyfikacji węzła na podstawie 13-elementowego wektora cech topologicznych, oraz zaproponowano autorski detektor LineageDetector. Wykazano, z potwierdzeniem statystycznym, że metody uczone przewyższają heurystyki, a LineageDetector przewyższa metody boostingowe (RUSBoost, LightGBM) w AUC-PR i Brier score. Detektor osiąga przy tym najwyższe średnie wartości wszystkich metryk, w tym AUC-ROC 0,771 i Brier score 0,106. Wobec Random Forest przewagi wykazać się nie udało, dlatego obie metody należy uznać za statystycznie nierozróżnialne przy dostępnej liczbie ośmiu grafów testowych. Badanie ablacyjne przypisało przewagę detektora relacyjnemu score’owi kompletności, ponieważ po jego usunięciu wynik spada do poziomu klasyfikatora bazowego. Przenośność detektora potwierdzono jakościowo na zewnętrznym grafie DUT.

PB3 – Obsługa rekurencji i UDF. W przyjętym ujęciu przyczyny broken lineage (UDF, tabele tymczasowe, zapytania rekurencyjne) są modelowane jednolicie, jako usunięcie węzła-zadania wraz z jego krawędziami, niezależnie od konkretnego mechanizmu. Dzięki temu detektor nie wymaga osobnej obsługi każdego typu transformacji. Ograniczeniem jest brak rozróżnienia przyczyny zerwania, co pozostaje otwartym kierunkiem.

PB4 – Metryki i datasety. Zastosowano zbiór DLG-DG-23 jako *ground truth* oraz metryki rankingowe czułe na nieźródnoważenie klas (AUC-ROC, AUC-PR, Precision@k/Recall@k/Hits@k, Brier). Zaproponowano protokół ewaluacji indukcyjnej cross-graph oraz kontrolę przecieku izolacji (`exclude_isolated`), element metodyczny niezbędny dla uczciwej oceny, dotąd nieobecny w literaturze broken lineage. Porównania metod oparto na teście kolejności par Wilcoxona sparowanym po grafach, zgodnie z zaleceniem Demšara [16]. Test ujawnił ograniczenie samego zbioru, ponieważ przy ośmiu grafach wiarygodnych najniższe osiągalne p wynosi 0,0078, przez co efekty małe pozostają niewykrywalne niezależnie od jakości metody. Jest to argument za rozbudową benchmarków lineage o większą liczbę grafów, a nie wyłącznie o grafy większe.

Wniosek główny. Sama topologia grafu lineage niesie umiarkowany, lecz użyteczny sygnał o broken lineage na poziomie węzłów (LineageDetector, AUC-ROC 0,771 w wariancie uczciwym i indukcyjnym). Praca wyznacza *topology-only baseline*, czyli punkt odniesienia dla bogatszych metod grafowo-semantycznych (grafy wiedzy, GNN). Pokazuje, ile można osiągnąć bez dostępu do nazw i schematów, i uzupełnia dotychczasowe podejścia o brakujące ujęcie węzłowe, w którym wskazanie podejrzanych tabel może poprzedzać kosztowniejsze odtwarzanie konkretnych zależności.

5.2 Kierunki dalszych badań

Uzyskane wyniki oraz ujawnione ograniczenia wskazują kilka kierunków, w których praca może być kontynuowana. Dotyczą one zarówno samych metod detekcji, jak i danych wykorzystywanych do ich oceny, a także sposobu powiązania detekcji tabel o zerwanym lineage z odtwarzaniem

brakujących zależności. Najważniejsze z nich omówiono poniżej, zaczynając od rozszerzeń metodycznych, a kończąc na zastosowaniach praktycznych.

- **Indukcyjne grafowe sieci neuronowe (GNN).** Naturalnym następnym krokiem po cechach topologicznych są modele uczące reprezentacji węzła z propagacją komunikatów: GraphSAGE [24], R-GCN [53] oraz HGT [28]. Metoda Node2Vec [22] została świadomie wykluczona z protokołu indukcyjnego, gdyż uczy zanurzeń transduktywnie (embeddingi nieporównywalne między grafami), co dodatkowo motywuje zastosowanie GNN.
- **Ilościowy benchmark na większym grafie zewnętrznym.** Wstępny test cross-dataset na grafie DUT (sekcja 4.9) pokazał, że detektor wytrenowany na DLG-DG-23 przenosi się na graf z innego źródła bez załamania. Graf ten był jednak bardzo mały (21 tabel) i miał łańcuchową topologię, przez co wynik ma charakter jakościowy. Naturalnym rozszerzeniem jest zbudowanie większego i bardziej rozgałęzionego grafu zewnętrznego (pełniejsza integracja benchmarku RDF grupy promotora [18]), który umożliwi wiarygodne porównanie ilościowe oraz ujawnienie przewagi sygnału relacyjnego, wymagającego rozgałęzień w grafie. Równie istotna jak rozmiar grafów jest ich liczba, ponieważ przy ośmiu grafach wiarygodnych moc testów statystycznych nie wystarcza do wykrycia różnic między metodami uczonymi (sekcja 4.11).
- **Włączenie semantyki nazw i schematów.** Sygnał topologiczny badany w pracy i sygnał semantyczny (podobieństwo nazw, metadane schematu) są komplementarne [6, 9]. Jeśli dane przestaną być zanonimizowane, połączenie obu powinno przekroczyć sufit $\approx 0,77$ właściwy podejściu czysto topologicznemu.
- **Potok dwuetapowy detekcja $\rightarrow$ predykcja.** Wskazanie podejrzanych tabel (niniejsza praca) może służyć jako tani etap wstępny, ograniczający przestrzeń kandydatów przed kosztowną predykcją konkretnych brakujących krawędzi, co połączyłoby oba ujęcia problemu broken lineage.
- **Rozróżnienie przyczyny zerwania.** Rozszerzenie etykiet o typ zdarzenia (UDF vs. tabela tymczasowa vs. CTE) umożliwiłoby nie tylko detekcję, lecz i diagnozę przyczyny broken lineage.

Literatura

- [1] ABSA Group. Spline: Data lineage tracking and visualization solution for Apache Spark, 2024. <https://absaoss.github.io/spline/>.
- [2] Leman Akoglu, Hanghang Tong, and Danai Koutra. Graph based anomaly detection and description: A survey. *Data Mining and Knowledge Discovery*, 29(3):626–688, 2015.
- [3] Witold Andrzejewski, Paweł Boiński, and Robert Wrembel. On Discovering Provenance of Data Warehouse Objects Created by Select-Project Queries. In *Proceedings of the Workshops of the EDBT/ICDT 2026 Joint Conference*, CEUR Workshop Proceedings, Tampere, Finland, 2026. CEUR-WS.org.
- [4] Apache Software Foundation. Apache Atlas: Data governance and metadata framework, 2024. <https://atlas.apache.org/>.
- [5] Albert-László Barabási and Réka Albert. Emergence of Scaling in Random Networks. *Science*, 286(5439):509–512, 1999.
- [6] Paweł Boiński, Witold Andrzejewski, Miłosz Grocholewski, Tobiasz Gruszczyński, and Robert Wrembel. Leveraging machine learning techniques for discovering broken lineage links between database objects. In *Proceedings of the 33rd International Conference on Information Systems Development (ISD2025)*, Belgrade, Serbia, 2025.
- [7] Leo Breiman. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [8] Glenn W. Brier. Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3, 1950.
- [9] Maciej Brzeski and Adam Roman. Inferring Missing Data Lineage Links from Schema Metadata Using Transformer-Based Models. In *Proceedings of the VLDB 2025 Workshop: Applied AI for Database Systems and Applications (AIDB 2025)*. VLDB Endowment, 2025.
- [10] Peter Buneman, Sanjeev Khanna, and Wang-Chiew Tan. Why and where: A characterization of data provenance. In *Proceedings of the 8th International Conference on Database Theory (ICDT)*, pages 316–330, 2001.
- [11] Yunpeng Chen, Ying Zhao, Xuanjing Li, Jiang Zhang, Jiang Long, and Fangfang Zhou. An open dataset of data lineage graphs for data governance research. *Visual Informatics*, 8:1–5, 2024.
- [12] Collibra. Collibra Data Lineage, 2024. <https://www.collibra.com/>.
- [13] Yingwei Cui and Jennifer Widom. Lineage tracing for general data warehouse transformations. *The VLDB Journal*, 12(1):41–58, 2003.
- [14] DataHub Project. DataHub: The metadata platform for the modern data stack, 2024. <https://datahubproject.io/>.
- [15] Jesse Davis and Mark Goadrich. The relationship between precision-recall and ROC curves. In *Proceedings of the 23rd International Conference on Machine Learning (ICML)*, pages 233–240, 2006.

- [16] Janez Demšar. Statistical comparisons of classifiers over multiple data sets. *Journal of Machine Learning Research*, 7:1–30, 2006.
- [17] Benjamin Dietrich, Tobias Müller, and Torsten Grust. Data Provenance for Recursive SQL Queries. In *Proceedings of the 14th Workshop on the Theory and Practice of Provenance (TaPP '22)*, Philadelphia, PA, USA, 2022. ACM.
- [18] Jakub Dutkiewicz, Paweł Misiorek, and Robert Wrembel. Data Lineage Discovery in Databases Based on Knowledge Graph Link Prediction. In *Proceedings of the Workshops of the EDBT/ICDT 2026 Joint Conference*, CEUR Workshop Proceedings, Tampere, Finland, 2026. CEUR-WS.org.
- [19] Tom Fawcett. An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.
- [20] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, 29(5):1189–1232, 2001.
- [21] Todd J. Green, Grigoris Karvounarakis, and Val Tannen. Provenance semirings. In *Proceedings of the 26th ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems (PODS)*, pages 31–40, 2007.
- [22] Aditya Grover and Jure Leskovec. node2vec: Scalable feature learning for networks. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 855–864, 2016.
- [23] Aric A. Hagberg, Daniel A. Schult, and Pieter J. Swart. Exploring network structure, dynamics, and function using NetworkX. In *Proceedings of the 7th Python in Science Conference (SciPy2008)*, pages 11–15, 2008.
- [24] William L. Hamilton, Rex Ying, and Jure Leskovec. Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 1024–1034, 2017.
- [25] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, et al. Array programming with NumPy. *Nature*, 585(7825):357–362, 2020.
- [26] Melanie Herschel, Ralf Diestelkämper, and Housseem Ben Lahmar. A survey on provenance: What for? What form? What from? *The VLDB Journal*, 26(6):881–906, 2017.
- [27] Sture Holm. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, 6(2):65–70, 1979.
- [28] Ziniu Hu, Yuxiao Dong, Kuansan Wang, and Yizhou Sun. Heterogeneous graph transformer. In *Proceedings of The Web Conference (WWW)*, pages 2704–2710, 2020.
- [29] John D. Hunter. Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3):90–95, 2007.
- [30] Leo Katz. A new status index derived from sociometric analysis. *Psychometrika*, 18(1):39–43, 1953.
- [31] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu. LightGBM: A highly efficient gradient boosting decision tree. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 3149–3157, 2017.
- [32] Barbara Kitchenham and Stuart Charters. Guidelines for performing systematic literature reviews in software engineering. Technical Report EBSE-2007-01, Keele University and University of Durham, 2007.
- [33] David Kohan Marzagão, Trung Dong Huynh, Ayah Helal, Sean Baccas, and Luc Moreau. Provenance Graph Kernel. *IEEE Transactions on Knowledge and Data Engineering*, 37(6):3653–3668, 2025.
- [34] István A. Kovács, Katja Luck, Kerstin Spirohn, Yang Wang, and Albert-László Barabási. Network-based prediction of protein interactions. *Nature Communications*, 10:1240, 2019.

- [35] Holger Krekel, Bruno Oliveira, Ronny Pfannschmidt, Floris Bruynooghe, Brianna Laughner, and Florian Bruhin. pytest, 2004. <https://github.com/pytest-dev/pytest>.
- [36] Timothy Lebo, Satya Sahoo, and Deborah McGuinness. PROV-O: The PROV ontology. W3C recommendation, World Wide Web Consortium (W3C), 2013. <https://www.w3.org/TR/prov-o/>.
- [37] Guillaume Lemaître, Fernando Nogueira, and Christos K. Aridas. Imbalanced-learn: A Python Toolbox to Tackle the Curse of Imbalanced Datasets in Machine Learning. *Journal of Machine Learning Research*, 18(17):1–5, 2017.
- [38] David Liben-Nowell and Jon Kleinberg. The Link-Prediction Problem for Social Networks. *Journal of the American Society for Information Science and Technology*, 58(7):1019–1031, 2007.
- [39] Xiaoxiao Ma, Jia Wu, Shan Xue, Jian Yang, Chuan Zhou, Quan Z. Sheng, Hui Xiong, and Leman Akoglu. A comprehensive survey on graph anomaly detection with deep learning. *IEEE Transactions on Knowledge and Data Engineering*, 35(12):12012–12038, 2023.
- [40] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.
- [41] Víctor Martínez, Fernando Berzal, and Juan-Carlos Cubero. A survey of link prediction in complex networks. *ACM Computing Surveys*, 49(4):1–33, 2016.
- [42] Wes McKinney. Data structures for statistical computing in Python. In *Proceedings of the 9th Python in Science Conference*, pages 56–61, 2010.
- [43] Microsoft. Northwind and pubs sample databases for SQL server, 2024. <https://github.com/microsoft/sql-server-samples/tree/master/samples/databases/northwind-pubs>.
- [44] Alexandru Niculescu-Mizil and Rich Caruana. Predicting good probabilities with supervised learning. In *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, pages 625–632, 2005.
- [45] OpenLineage Project. OpenLineage: An open framework for data lineage collection and analysis, 2024. Projekt Linux Foundation, <https://openlineage.io/>.
- [46] Lawrence Page, Sergey Brin, Rajeev Motwani, and Terry Winograd. The PageRank citation ranking: Bringing order to the web. Technical Report 1999-66, Stanford InfoLab, 1999.
- [47] Parlament Europejski i Rada Unii Europejskiej. Rozporządzenie (UE) 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych oraz uchylenia dyrektywy 95/46/WE (ogólne rozporządzenie o ochronie danych), 2016. Dziennik Urzędowy Unii Europejskiej L 119, s. 1–88.
- [48] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [49] John C. Platt. Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. In Alexander J. Smola, Peter Bartlett, Bernhard Schölkopf, and Dale Schuurmans, editors, *Advances in Large Margin Classifiers*, pages 61–74. MIT Press, 1999.
- [50] Fotis Psallidas, Ashvin Agrawal, Chandru Sugunan, Khaled Ibrahim, Konstantinos Karanasos, Jesús Camacho-Rodríguez, Avrielia Floratou, Carlo Curino, and Raghu Ramakrishnan. OneProvenance: Efficient Extraction of Dynamic Coarse-Grained Provenance From Database Query Event Logs. *Proceedings of the VLDB Endowment*, 16(12):3662–3675, 2023. Wdrożone w Microsoft Purview.
- [51] Python Software Foundation. Python language reference, version 3.10, 2021. <https://www.python.org/>.

- [52] Takaya Saito and Marc Rehmsmeier. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3):e0118432, 2015.
- [53] Michael Schlichtkrull, Thomas N. Kipf, Peter Bloem, Rianne van den Berg, Ivan Titov, and Max Welling. Modeling relational data with graph convolutional networks. In *The Semantic Web (ESWC)*, pages 593–607, 2018.
- [54] Chris Seiffert, Taghi M. Khoshgoftaar, Jason Van Hulse, and Amri Napolitano. RUSBoost: A hybrid approach to alleviating class imbalance. *IEEE Transactions on Systems, Man, and Cybernetics — Part A*, 40(1):185–197, 2010.
- [55] Dibin Shan, Xuehui Du, Wenjuan Wang, Na Wang, and Aodi Liu. KPI-HGNN: Key Provenance Identification Based on a Heterogeneous Graph Neural Network for Big Data Access Control. *Information Sciences*, 659:120059, 2024.
- [56] Carolin Strobl, Anne-Laure Boulesteix, Achim Zeileis, and Torsten Hothorn. Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics*, 8:25, 2007.
- [57] Pauli Virtanen, Ralf Gommers, Travis E. Oliphant, et al. SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3):261–272, 2020.
- [58] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80–83, 1945.
- [59] Claes Wohlin, Per Runeson, Martin Höst, Magnus C. Ohlsson, Björn Regnell, and Anders Wesslén. *Experimentation in Software Engineering*. Springer, 2012.
- [60] Masaya Yamada, Hiroyuki Kitagawa, Toshiyuki Amagasa, and Akiyoshi Matono. Augmented lineage: traceability of data analysis including complex UDF processing. *The VLDB Journal*, 32(5):963–983, 2023.
- [61] Bianca Zadrozny and Charles Elkan. Transforming classifier scores into accurate multiclass probability estimates. In *Proceedings of the 8th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 694–699, 2002.

Dodatek A

Instrukcja uruchomienia i zawartość repozytorium

A.1 Wymagania i instalacja

Implementacja wymaga interpretera Python w wersji 3.10 lub nowszej. Zależności wraz z wersjami użytymi w biegu kanonicznym wymieniono w tabeli 3.4. Środowisko przygotowuje się poleceniami:

```
python -m venv .venv
.venv\Scripts\activate          # Windows
pip install -r requirements.txt
```

A.2 Odtworzenie wyników rozdziału 4

Każdą tabelę rozdziału 4 można odtworzyć niezależnie. Polecenia uruchamia się z katalogu głównego repozytorium. Wszystkie zapisują wyniki do katalogu `results/`.

```
# Bieg kanoniczny -- wariant uczciwy (tabela wynikow glownych)
python -m src.detection.run_detection_experiments --all \
    --exclude-isolated --removal-ratio 0.10 --repeats 3 --seed 42 \
    --csv results/wyniki_detekcja_canon.csv

# Bieg kanoniczny -- wariant zawyżony (kontrola przecieku izolacji)
python -m src.detection.run_detection_experiments --all \
    --removal-ratio 0.10 --repeats 3 --seed 42 \
    --csv results/wyniki_detekcja_napompowany.csv

# Testy istotnosci statystycznej
python scripts/test_istotnosci.py

# Badanie ablacyjne detektora
python src/detection/run_ablation.py
python scripts/test_istotnosci.py --ablacja

# Waznosc cech (metoda permutacyjna)
python scripts/waznosc_cech.py

# Analiza wzraliwosci na removal_ratio
```

```
python -m src.detection.run_removal_sensitivity

# Warianty protokołu -- wszystkie w konfiguracji kanonicznej
python -m src.detection.run_detection_experiments --all --single-job \
    --exclude-isolated --removal-ratio 0.10 --repeats 3 --seed 42 \
    --csv results/wyniki_jednojob.csv
python -m src.detection.run_transductive \
    --exclude-isolated --removal-ratio 0.10 --repeats 3
python -m src.detection.run_scale_generalization \
    --exclude-isolated --removal-ratio 0.10 --repeats 3

# Test cross-dataset na grafie zewnętrznym DUT
python -m src.detection.run_cross_dataset

# Tabela charakterystyki symulacji (rozdział 3)
python scripts/tabela_symulacji.py

# Tabele Dodatku B
python scripts/dodatek_wyniki.py
```

Warianty protokołu wymagają jawnego podania flag `-exclude-isolated` i `-removal-ratio 0.10`, ponieważ ich wartości domyślne różnią się od biegu kanonicznego, a porównanie protokołów ma sens tylko przy identycznej konfiguracji pozostałych parametrów.

Zestaw testów jednostkowych uruchamia się poleceniem `pytest` z katalogu głównego. Wszystkie 83 testy powinny zakończyć się powodzeniem.

A.3 Zawartość repozytorium

Strukturę katalogów przedstawia listing 3.1 w sekcji 3.6. Adres repozytorium podano w sekcji 3.8. Katalog `results/` zawiera pliki CSV z wynikami wszystkich biegów oraz plik `README_BIEG_KANONICZNY.md` dokumentujący konfigurację biegu, z którego pochodzą liczby raportowane w pracy.

Dodatek B

Pełne wyniki eksperymentów

Tabele rozdziału 4 podają wartości uśrednione po grafach wiarygodnych. Niniejszy dodatek zawiera wyniki biegu kanonicznego dla wszystkich 18 grafów zbioru DLG-DG-23 i wszystkich czterech metryk, wraz z grafami odrzuconymi z agregacji progiem $\text{MIN_POS} = 5$. Grafy te oznaczono gwiazdką. Ich metryki obliczono, lecz przy jednym lub dwóch pozytywach w zbiorze testowym są one obciążone bardzo dużą wariancją i nie powinny być interpretowane pojedynczo. Zestawienie pozwala czytelnikowi ocenić, co próg wiarygodności odsiewa i jak duży jest rozrzut wyników. Tabele B.1–B.4 przedstawiają kolejno AUC-ROC, AUC-PR, Precision@k oraz Brier score.

TABELA B.1: AUC-ROC dla wszystkich 18 grafów zbioru DLG-DG-23 (wyższa wartość jest lepsza). Gwiazdką oznaczono grafy odrzucone z agregacji progiem $\text{MIN_POS} = 5$.

Graf	Kand.	Zainf.	Stopień	Brzeg	Łączn.	Korzeń	Kompl.	RF	RUSB	LGBM	LD*
DLG1*	13	1	0,727	0,583	0,692	0,792	0,500	0,545	0,500	0,591	0,818
DLG2*	21	1	0,556	0,583	0,079	0,461	0,474	0,645	0,750	0,632	0,763
DLG3*	26	3	0,142	0,591	0,295	0,761	0,477	0,598	0,644	0,659	0,674
DLG4*	16	1	0,475	0,567	0,050	0,750	0,375	0,750	0,967	0,700	0,933
DLG5	66	9	0,405	0,340	0,233	0,590	0,567	0,662	0,703	0,633	0,745
DLG6	568	82	0,439	0,480	0,309	0,567	0,627	0,745	0,619	0,707	0,790
DLG7*	29	1	0,125	0,339	0,312	0,179	0,446	0,464	0,500	0,625	0,821
DLG8*	18	2	0,382	0,400	0,422	0,515	0,353	0,735	0,500	0,647	0,789
DLG9*	24	3	0,217	0,193	0,222	0,159	0,205	0,580	0,591	0,625	0,517
DLG10	213	36	0,417	0,472	0,323	0,544	0,428	0,681	0,586	0,588	0,714
DLG11	65	6	0,513	0,454	0,386	0,642	0,492	0,732	0,658	0,776	0,804
DLG12	197	26	0,356	0,469	0,389	0,457	0,585	0,855	0,604	0,837	0,869
DLG13	100	13	0,446	0,445	0,198	0,678	0,602	0,723	0,674	0,697	0,692
DLG14*	9	1	0,000	0,000	0,000	0,059	0,382	0,882	0,500	0,882	0,088
DLG15*	25	2	0,587	0,450	0,460	0,380	0,413	0,580	0,600	0,670	0,770
DLG16	246	44	0,451	0,498	0,366	0,565	0,626	0,841	0,599	0,783	0,818
DLG17*	24	2	0,000	0,043	0,043	0,217	0,283	0,739	0,478	0,913	0,957
DLG18	625	110	0,386	0,481	0,389	0,549	0,547	0,750	0,601	0,737	0,733
<i>średnia</i>			0,427	0,455	0,324	0,574	0,559	0,749	0,631	0,720	0,771

Skróty metod: Stopień – anomalia stopnia, Brzeg – root/leaf, Łączn. – niska łączność zadań, Korzeń – reguła korzenia, Kompl. – score kompletności, RF – Random Forest, RUSB – RUSBoost, LGBM – LightGBM, LD* – LineageDetector (wkład własny). Średnia liczona wyłącznie po grafach wiarygodnych.

TABELA B.2: AUC-PR dla wszystkich 18 grafów zbioru DLG-DG-23 (wyższa wartość jest lepsza). Gwiazdką oznaczono grafy odrzucone z agregacji progiem MIN_POS = 5.

Graf	Kand.	Zainf.	Stopień	Brzeg	Łączn.	Korzeń	Kompl.	RF	RUSB	LGBM	LD*
DLG1*	13	1	0,310	0,091	0,125	0,167	0,077	0,225	0,077	0,250	0,450
DLG2*	21	1	0,139	0,077	0,074	0,089	0,095	0,562	0,548	0,562	0,591
DLG3*	26	3	0,111	0,182	0,121	0,320	0,154	0,457	0,365	0,404	0,588
DLG4*	16	1	0,083	0,056	0,050	0,091	0,062	0,167	0,500	0,143	0,500
DLG5	66	9	0,284	0,127	0,097	0,168	0,258	0,373	0,323	0,460	0,469
DLG6	568	82	0,140	0,140	0,105	0,170	0,229	0,378	0,234	0,354	0,427
DLG7*	29	1	0,038	0,043	0,045	0,034	0,034	0,062	0,034	0,130	0,167
DLG8*	18	2	0,083	0,086	0,085	0,108	0,105	0,250	0,167	0,562	0,567
DLG9*	24	3	0,096	0,115	0,095	0,115	0,115	0,217	0,115	0,248	0,200
DLG10	213	36	0,177	0,168	0,129	0,195	0,188	0,382	0,246	0,370	0,397
DLG11	65	6	0,132	0,100	0,081	0,150	0,108	0,355	0,279	0,327	0,368
DLG12	197	26	0,125	0,111	0,103	0,115	0,219	0,478	0,236	0,342	0,474
DLG13	100	13	0,120	0,110	0,081	0,180	0,129	0,349	0,259	0,300	0,380
DLG14*	9	1	0,056	0,056	0,056	0,056	0,056	0,333	0,056	0,333	0,059
DLG15*	25	2	0,084	0,062	0,068	0,068	0,080	0,262	0,360	0,302	0,512
DLG16	246	44	0,201	0,166	0,143	0,163	0,301	0,613	0,196	0,506	0,518
DLG17*	24	2	0,042	0,042	0,043	0,042	0,042	0,200	0,042	0,333	0,500
DLG18	625	110	0,143	0,177	0,155	0,199	0,218	0,472	0,223	0,393	0,448
<i>średnia</i>			0,165	0,137	0,112	0,168	0,206	0,425	0,249	0,381	0,435

Skróty metod: Stopień – anomalia stopnia, Brzeg – root/leaf, Łączn. – niska łączność zadań, Korzeń – reguła korzenia, Kompl. – score kompletności, RF – Random Forest, RUSB – RUSBoost, LGBM – LightGBM, LD* – LineageDetector (wkład własny). Średnia liczona wyłącznie po grafach wiarygodnych.

TABELA B.3: Precision@k dla wszystkich 18 grafów zbioru DLG-DG-23 (wyższa wartość jest lepsza). Gwiazdką oznaczono grafy odrzucone z agregacji progiem MIN_POS = 5.

Graf	Kand.	Zainf.	Stopień	Brzeg	Łączn.	Korzeń	Kompl.	RF	RUSB	LGBM	LD*
DLG1*	13	1	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
DLG2*	21	1	0,000	0,000	0,000	0,000	0,000	0,500	0,500	0,500	0,500
DLG3*	26	3	0,000	0,000	0,250	0,250	0,000	0,500	0,333	0,500	0,500
DLG4*	16	1	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
DLG5	66	9	0,273	0,111	0,000	0,444	0,273	0,364	0,444	0,444	0,444
DLG6	568	82	0,138	0,138	0,068	0,191	0,311	0,340	0,338	0,351	0,432
DLG7*	29	1	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
DLG8*	18	2	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,500	0,333
DLG9*	24	3	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
DLG10	213	36	0,140	0,133	0,056	0,139	0,070	0,349	0,349	0,361	0,395
DLG11	65	6	0,143	0,167	0,167	0,000	0,333	0,167	0,333	0,333	0,333
DLG12	197	26	0,182	0,080	0,080	0,080	0,280	0,520	0,273	0,406	0,480
DLG13	100	13	0,000	0,167	0,083	0,176	0,000	0,250	0,417	0,333	0,417
DLG14*	9	1	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000
DLG15*	25	2	0,000	0,000	0,000	0,000	0,000	0,200	0,200	0,200	0,600
DLG16	246	44	0,146	0,214	0,179	0,195	0,400	0,600	0,317	0,500	0,585
DLG17*	24	2	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,000	0,250
DLG18	625	110	0,117	0,157	0,117	0,214	0,252	0,447	0,252	0,456	0,456
<i>średnia</i>			0,142	0,146	0,094	0,180	0,240	0,380	0,340	0,398	0,443

Skróty metod: Stopień – anomalia stopnia, Brzeg – root/leaf, Łączn. – niska łączność zadań, Korzeń – reguła korzenia, Kompl. – score kompletności, RF – Random Forest, RUSB – RUSBoost, LGBM – LightGBM, LD* – LineageDetector (wkład własny). Średnia liczona wyłącznie po grafach wiarygodnych.

TABELA B.4: Brier score dla wszystkich 18 grafów zbioru DLG-DG-23 (niższa wartość jest lepsza). Gwiazdką oznaczono grafy odrzucone z agregacji progiem MIN_POS = 5.

Graf	Kand.	Zainf.	Stopień	Brzeg	Łączn.	Korzeń	Kompl.	RF	RUSB	LGBM	LD*
DLG1*	13	1	0,071	0,769	0,192	0,385	0,077	0,129	0,123	0,181	0,109
DLG2*	21	1	0,086	0,750	0,228	0,571	0,100	0,106	0,050	0,158	0,073
DLG3*	26	3	0,146	0,692	0,209	0,231	0,192	0,127	0,102	0,163	0,108
DLG4*	16	1	0,058	0,812	0,245	0,476	0,107	0,090	0,050	0,153	0,054
DLG5	66	9	0,132	0,815	0,243	0,385	0,133	0,146	0,155	0,171	0,115
DLG6	568	82	0,133	0,694	0,221	0,460	0,141	0,115	0,151	0,141	0,099
DLG7*	29	1	0,038	0,793	0,227	0,655	0,060	0,140	0,065	0,395	0,050
DLG8*	18	2	0,106	0,778	0,244	0,474	0,194	0,124	0,099	0,167	0,078
DLG9*	24	3	0,116	0,846	0,228	0,731	0,234	0,178	0,161	0,214	0,105
DLG10	213	36	0,166	0,759	0,231	0,553	0,185	0,162	0,156	0,161	0,136
DLG11	65	6	0,088	0,862	0,247	0,415	0,108	0,097	0,075	0,122	0,070
DLG12	197	26	0,117	0,732	0,204	0,611	0,123	0,097	0,131	0,131	0,089
DLG13	100	13	0,112	0,850	0,242	0,440	0,126	0,113	0,113	0,180	0,106
DLG14*	9	1	0,054	1,000	0,261	0,889	0,130	0,151	0,086	0,072	0,086
DLG15*	25	2	0,082	0,875	0,236	0,720	0,133	0,135	0,078	0,162	0,086
DLG16	246	44	0,149	0,605	0,208	0,419	0,158	0,085	0,188	0,117	0,105
DLG17*	24	2	0,046	0,917	0,239	0,583	0,176	0,086	0,078	0,198	0,046
DLG18	625	110	0,170	0,643	0,215	0,470	0,181	0,125	0,249	0,156	0,128
<i>średnia</i>			0,134	0,745	0,226	0,469	0,144	0,117	0,152	0,147	0,106

Skróty metod: Stopień – anomalia stopnia, Brzeg – root/leaf, Łączn. – niska łączność zadań, Korzeń – reguła korzenia, Kompl. – score kompletności, RF – Random Forest, RUSB – RUSBoost, LGBM – LightGBM, LD* – LineageDetector (wkład własny). Średnia liczona wyłącznie po grafach wiarygodnych.

Dodatek C

Przegląd konfiguracji testu cross-dataset

Sekcja 4.9 raportuje wynik na zewnętrznym grafie DUT dla jednej konfiguracji. Aby sprawdzić, czy wnioski nie zależą od jej doboru, test powtórzono dla dwóch wariantów izolacji i trzech wartości parametru `removal_ratio`, po 25 powtórzeniach na konfigurację. Tabela C.1 zestawia AUC-ROC. Pełne wyniki, obejmujące pozostałe metryki, zawiera plik `results/cross_dataset_dut_sweep.md` w repozytorium.

TABELA C.1: AUC-ROC na zewnętrznym grafie DUT w zależności od wariantu izolacji i parametru `removal_ratio` (trening na małych i średnich grafach DLG-DG-23, 25 powtórzeń na konfigurację).

Metoda	Wariant zawyżony			Wariant uczciwy		
	0,2	0,3	0,4	0,2	0,3	0,4
Anomalia stopnia	0,851	0,866	0,881	0,766	0,762	0,748
Brzeg (root/leaf)	0,828	0,847	0,873	0,726	0,725	0,727
Niska łączność zadań	0,851	0,866	0,881	0,766	0,762	0,748
Score kompletności	0,500	0,500	0,500	0,500	0,500	0,500
Reguła korzenia	0,705	0,723	0,779	0,630	0,622	0,686
Random Forest	0,758	0,793	0,847	0,646	0,618	0,680
RUSBoost	0,627	0,681	0,765	0,484	0,483	0,504
LightGBM	0,794	0,813	0,845	0,663	0,664	0,656
LineageDetector*	0,767	0,812	0,843	0,654	0,646	0,684
<i>śr. liczba zainfekowanych</i>	6,6	8,5	12,2	3,9	4,5	5,4

Uwagę zwraca wiersz score’u kompletności, w którym wartość 0,500 powtarza się we wszystkich sześciu konfiguracjach, co potwierdza, że sygnał peer-consistency jest na tym grafie tożsamościowo zerowy z przyczyn strukturalnych, a nie przypadkowo słaby, ponieważ topologia łańcuchowa nie daje tabelom peerów. Ostatni wiersz wyjaśnia z kolei, dlaczego wariant uczciwy wypada gorzej od zawyżonego. Przy 21 tabelach-kandydatach liczba pozytywów spada do czterech, czyli poniżej progu wiarygodności przyjętego dla DLG-DG-23.



© 2026 Maria Nowicka

Instytut Informatyki, Wydział Informatyki i Telekomunikacji
Politechnika Poznańska

Skład przy użyciu systemu $\text{\LaTeX}$ na platformie Overleaf.